

Análisis de sentimientos sobre el Codex Gigas: propuesta de investigación

Antonio Soria

Divulgación Científica — purplealien.github.io

Julio 2026

Resumen

El Codex Gigas — la “Biblia del Diablo” — es el manuscrito medieval más grande que se conserva: 75 kilogramos de vitela escritos, según el análisis paleográfico, por una sola mano a lo largo de décadas. Este artículo presenta mi próxima línea de investigación: aplicar procesamiento de lenguaje natural y modelos de lenguaje contextuales para latín al contenido del códice, con el objetivo de construir un *mapa emocional* computacional de sus textos, de los evangelios a las fórmulas de exorcismo. Se describen el corpus, la metodología propuesta, los retos técnicos y los resultados esperados.

1. El objeto: un libro imposible

El Codex Gigas fue creado a inicios del siglo XIII (se estima entre 1204 y 1230) en el monasterio benedictino de Podlažice, en Bohemia — la actual República Checa. Sus números intimidan: 92 cm de alto, 50 de ancho, 22 de grosor, 74.8 kg de peso y 310 hojas de vitela que habrían requerido las pieles de más de 150 animales. El análisis de la caligrafía indica un solo escriba — la tradición lo llama Herman el Recluso — trabajando quizá veinte o treinta años.

La leyenda que le da su apodo cuenta que un monje condenado a ser emparedado vivo prometió escribir en una sola noche un libro con todo el conocimiento humano, y al verse perdido cerca de la medianoche vendió su alma al diablo para terminarlo. Como firma del pacto, el folio 290 recto exhibe un retrato del demonio a página completa — exactamente frente a una representación de la Ciudad Celestial. Desde 1648, cuando las tropas suecas lo tomaron como botín de guerra en Praga, se conserva en la Biblioteca Nacional de Suecia en Estocolmo, que mantiene una digitalización completa de acceso público.

1.1. El contenido: una biblioteca en un solo lomo

Para un proyecto de NLP, lo valioso del códice es su heterogeneidad textual. Contiene, en latín: la Biblia completa (Antiguo y Nuevo Testamento en versión Vulgata), las *Antigüedades* y *La guerra de los judíos* de Flavio Josefo, las *Etimologías* de Isidoro de Sevilla (la enciclopedia estándar medieval), el *Ars medicinae* y textos médicos de la escuela salernitana, la *Chronica Boemorum* de Cosmas de Praga, un calendario con necrologio, listas de nombres, y — lo más jugoso para un análisis emocional — conjuros mágicos y fórmulas de exorcismo. Géneros radicalmente distintos: narrativa sagrada, historia, enciclopedia, medicina, crónica local y magia ritual, todos copiados por la misma mano.

2. La pregunta de investigación

El análisis de sentimientos (*sentiment analysis*) detecta computacionalmente la polaridad (positivo/negativo) y las emociones (miedo, alegría, ira...) expresadas en un texto. Aplicado al Codex Gigas, propongo responder tres preguntas:

1. ¿Cómo se distribuye el contenido emocional a lo largo del código? ¿Existe un *perfil afectivo* distinguible por género textual — evangelios frente a crónicas frente a exorcismos?
2. ¿Las fórmulas de exorcismo y los conjuros exhiben marcadores emocionales (miedo, amenaza, imperativo) cuantitativamente distintos del resto del corpus?
3. ¿Puede el análisis computacional aportar evidencia sobre la organización interna del código — por ejemplo, si la colocación del retrato del diablo junto a la Ciudad Celestial responde a un contraste deliberado que se refleja también en la selección textual circundante?

3. Metodología propuesta

3.1. Corpus y digitalización

No parto de las imágenes del manuscrito: la transcripción directa (HTR, *Handwritten Text Recognition* sobre minúscula carolina tardía) es un proyecto en sí mismo. La estrategia práctica es ensamblar el corpus desde ediciones digitales existentes de los textos que el código contiene — la Vulgata, Josefo, Isidoro y Cosmas están disponibles en repositorios como Perseus y la Latin Library — y usar la digitalización de la Biblioteca Nacional de Suecia para verificar la composición y las secciones exclusivas (conjuros, calendario).

3.2. Modelos: NLP para una lengua sin hablantes

El reto central es que el corpus está en latín medieval, una lengua de “bajos recursos” para el NLP moderno: no hay léxicos de sentimiento nativos ni corpus anotados de emociones. El plan combina tres niveles:

1. **Base contextual:** Latin BERT (Bamman y Burns, 2020), el primer modelo de lenguaje contextual para latín, entrenado con 642.7 millones de tokens que abarcan 22 siglos de producción escrita. Provee representaciones vectoriales sensibles al contexto para cada palabra del corpus.
2. **Proyección de léxicos:** transferir léxicos de emociones modernos (como el NRC Emotion Lexicon) al latín vía los espacios de embeddings, con validación manual de las entradas más frecuentes — la traducción automática de léxicos es ruidosa y el vocabulario religioso medieval tiene cargas semánticas propias (*timor Domini*, el temor de Dios, no es simplemente “miedo”).
3. **Clasificación supervisada ligera:** anotar manualmente una muestra estratificada de pasajes (con criterios explícitos y verificación de acuerdo entre anotadores) para afinar un clasificador sobre las representaciones de Latin BERT, siguiendo la estrategia que ha funcionado en otras lenguas históricas como el chino clásico.

3.3. Análisis

Con el corpus etiquetado, el análisis es estadístico: distribución de polaridad y emociones por obra y por género, series “narrativas” de emoción a lo largo de cada libro (el arco emocional de los evangelios frente al del Apocalipsis, por ejemplo), y contraste de hipótesis sobre los exorcismos

frente a secciones de control. La visualización final — un mapa emocional navegable del código — se publicará como demo interactiva en mi sitio, como hice con mi anterior proyecto de detección de paráfrasis.

4. Retos y honestidad metodológica

Este proyecto exige cautelas que conviene declarar desde el diseño. Primera: los conceptos emocionales son culturales; proyectar categorías del siglo XXI sobre textos del XIII es un acto interpretativo que debe hacerse explícito, no esconderse tras la aparente neutralidad del número. Segunda: el latín de la Vulgata es traducción de originales hebreos y griegos — el sentimiento medido es el del texto latino que el escriba copió, no “el de la Biblia”. Tercera: la validación con especialistas en filología medieval no es opcional; un clasificador puede ser estadísticamente sólido y filológicamente absurdo. El valor del proyecto está precisamente en el diálogo entre la escala computacional (imposible para la lectura humana) y el juicio experto (imposible para la máquina).

5. Resultados esperados

Espero producir: (1) un corpus latino estructurado y alineado con la composición del código, reutilizable por otros investigadores; (2) un léxico de sentimientos para latín medieval validado parcialmente a mano; (3) el análisis emocional comparativo entre géneros del código; y (4) la visualización interactiva pública. Más allá de los resultados concretos, la apuesta de fondo es metodológica: demostrar que las humanidades digitales pueden tratar objetos patrimoniales complejos con el mismo rigor técnico que cualquier corpus moderno — y que un manuscrito del siglo XIII envuelto en leyendas diabólicas es, también, un dataset.

Referencias principales

- Bamman, D. y Burns, P. J., *Latin BERT: A Contextual Language Model for Classical Philology* (2020). <https://arxiv.org/abs/2009.10053>
- Mohammad, S., *Sentiment Analysis: Automatically Detecting Valence, Emotions, and Other Affectual States from Text* (2020). <https://arxiv.org/abs/2005.11882>
- Biblioteca Nacional de Suecia, *The Codex Gigas*. <https://www.kb.se/eng/the-codex-gigas/>
- Riemenschneider, F. y Frank, A., *Exploring Large Language Models for Classical Philology* (2023). <https://arxiv.org/abs/2305.13698>