



Casa abierta al tiempo

Universidad Autónoma Metropolitana

Unidad Iztapalapa

División de Ciencias Básicas e Ingeniería

Licenciatura en Computación

Proyecto Terminal de Investigación 1

Reporte Final

Detección Inteligente de Paráfrasis mediante Modelos de Lenguaje de Gran Escala (LLM).

Un detector honesto sobre el corpus TESIUAMI de las tres divisiones (CBI, CBS y CSH), con evaluación bajo intervalos de confianza y sistema desplegado en producción

Asesor: Dr. Benjamin Moreno Montiel

Alumno: Juan Antonio Soria Rodríguez

Matrícula: 2203041232

Grupo: CK06

Fecha: Agosto 2026

A mi familia, por su apoyo incondicional a lo largo de la carrera.

Agradecimientos

Agradezco a la Universidad Autónoma Metropolitana, Unidad Iztapalapa, y a la Licenciatura en Computación por la formación recibida.

Al Dr. Benjamín Moreno Montiel, asesor de este proyecto, por su guía, su exigencia y su acompañamiento constante a lo largo del desarrollo del trabajo.

A mis profesores, compañeros y familia, por el apoyo brindado durante toda la carrera.

Resumen

La detección de paráfrasis y copia es un problema central para la integridad académica. Este proyecto aborda la detección automática de paráfrasis sobre el corpus de tesis **TESIUAMI** de la Universidad Autónoma Metropolitana, Unidad Iztapalapa, empleando **modelos de lenguaje de gran escala (LLM)** y modelos tipo Transformer afinados (BETO, XLM-RoBERTa), en contraste con el enfoque previo basado en redes convolucionales y *embeddings* estáticos de la tesis base de David Luna.

Se construyó un sistema de *doble modo* que (a) clasifica pares de textos como paráfrasis o no, y (b) analiza documentos completos contra un corpus interno de **21,128 tesis** de las tres divisiones de la unidad (CBI, CBS y CSH) y contra un corpus científico externo de ~ 250 millones de obras (OpenAlex, Semantic Scholar y Crossref). El sistema combina recuperación híbrida (semántica con HNSW, léxica con BM25 y fusión por RRF) con un clasificador cruzado cuantizado a int8, y se encuentra **desplegado en producción**.

El resultado metodológico principal es un **encuadre honesto** de la evaluación: toda métrica se reporta con su conjunto de prueba etiquetado y con intervalos de confianza, descartando cifras infladas por fuga de datos o balanceo artificial. Bajo ese encuadre, el mejor modelo afinado (BETO v3) alcanza **F1 = 0.842** sobre el conjunto de prueba limpio, *empatando* —dentro del intervalo de confianza— con la línea base de la tesis previa; el aporte no es superar esa cifra, sino la **eficiencia de datos** (lograrlo con decenas de pares anotados en lugar de cientos de miles). Dos hallazgos sostienen la tesis central del trabajo, «*el dato supera a la arquitectura*»: (i) los datos sintéticos (generados por LLM y por retro-traducción) **degradan** el desempeño, y (ii) una búsqueda exhaustiva sobre el corpus muestra que **el corpus es original** —la copia parafraseada entre tesis es prácticamente nula—, por lo que la similitud temática no debe confundirse con plagio.

Palabras clave: detección de paráfrasis, procesamiento de lenguaje natural, modelos de lenguaje de gran escala, BERT, XLM-RoBERTa, recuperación de información, integridad académica.

Abstract

Paraphrase and copy detection is a central problem for academic integrity. This project addresses automatic paraphrase detection over the **TESIUAMI** thesis corpus of the Universidad Autónoma Metropolitana, Iztapalapa, using **large language models (LLM)** and fine-tuned Transformer models (BETO, XLM-RoBERTa), in contrast with the previous approach based on convolutional networks and static embeddings from David Luna’s base thesis.

A *dual-mode* system was built that (a) classifies pairs of texts as paraphrase or not, and (b) analyzes complete documents against an internal corpus of **21,128 theses** from the three divisions of the unit (CBI, CBS and CSH) and against an external scientific corpus of ~ 250 million works (OpenAlex, Semantic Scholar and Crossref). The system combines hybrid retrieval (semantic HNSW, lexical BM25 and RRF fusion) with an int8-quantized cross-encoder classifier, and is **deployed in production**.

The main methodological result is an **honest evaluation framing**: every metric is reported with its labeled test set and confidence intervals, discarding figures inflated by data leakage or artificial balancing. Under this framing, the best fine-tuned model (BETO v3) reaches **F1 = 0.842** on the clean test set, *tying* —within the confidence interval— with the baseline of the previous thesis; the contribution is not to beat that figure but the **data efficiency** of achieving it with a few dozen annotated pairs rather than hundreds of thousands. Two findings support the project’s central thesis, “*data beats architecture*”: (i) synthetic data (LLM-generated and back-translated) **degrade** performance, and (ii) an exhaustive search over the corpus shows that **the corpus is original** —paraphrased copying between theses is practically nil—, so thematic similarity must not be confused with plagiarism.

Keywords: paraphrase detection, natural language processing, large language models, BERT, XLM-RoBERTa, information retrieval, academic integrity.

Índice general

Agradecimientos	II
Resumen	III
Abstract	IV
Lista de acrónimos	XI
1. Introducción	1
1.1. Motivación y contexto	1
1.2. Planteamiento del problema	1
1.3. Hipótesis	1
1.4. Objetivos	2
1.4.1. Objetivo general	2
1.4.2. Objetivos particulares	2
1.5. Metodología (resumen)	2
1.6. Justificación	2
1.7. Contribuciones	2
1.8. Alcances y limitaciones	3
1.9. Organización del documento	3
2. Antecedentes	4
2.1. Procesamiento del lenguaje natural	4
2.2. La tarea de detección de paráfrasis	4
2.3. De las representaciones estáticas a los Transformers	5
2.3.1. Representaciones estáticas: TF-IDF, Word2Vec y FastText	5
2.3.2. Transformers, BERT y sus variantes en español y multilingües	5
2.3.3. Bi-codificadores frente a codificadores cruzados	5
2.4. Recuperación de información vectorial	6
2.4.1. Búsqueda por similitud aproximada: FAISS, HNSW e IVFPQ	6
2.4.2. Recuperación léxica: BM25	6
2.4.3. Fusión de rankings: Reciprocal Rank Fusion	6
2.5. Modelos de lenguaje de gran escala e <i>in-context learning</i>	6
2.6. Métricas y evaluación	6
2.6.1. Precisión, <i>recall</i> , F1 y AUROC	6
2.6.2. Intervalos de confianza y significancia estadística	7
2.6.3. Calibración de probabilidades	7

3. Estado del arte	8
3.1. Corpus de paráfrasis	8
3.2. La tesis base: detección de paráfrasis con aprendizaje maquinal	8
3.3. Detección de paráfrasis con modelos contextuales y LLM	9
3.4. Datos sintéticos para el procesamiento del lenguaje	9
3.5. Sistemas comerciales de detección de similitud	9
4. Metodología	10
4.1. El corpus TESIUAMI	10
4.1.1. Extracción y limpieza	10
4.1.2. Las tres divisiones: CBI, CBS y CSH	10
4.1.3. Fragmentación por ventanas deslizantes	10
4.1.4. Idioma del corpus	11
4.2. Modelos evaluados	11
4.3. Protocolo de evaluación honesto	11
4.3.1. Fuga de datos y balanceo artificial	11
4.3.2. El «número doble/triple»: conjuntos de prueba etiquetados	12
4.3.3. Intervalos de confianza y significancia	13
4.4. Afinamiento de modelos (<i>fine-tuning</i>)	13
4.5. Calibración	13
4.6. Desarrollo iterativo del proyecto y requerimientos del asesor	14
4.7. Auditoría independiente	15
5. Diseño e implementación del sistema	16
5.1. Arquitectura general: recuperar → clasificar	16
5.2. Modo 1: clasificación de pares	16
5.3. Modo 2: análisis de documento completo	16
5.3.1. Recuperación híbrida: HNSW + BM25 + RRF	17
5.3.2. Reporte estilo «informe de similitud»	17
5.4. Corpus científico externo (federado)	18
5.5. Optimización y despliegue	18
5.5.1. Cuantización int8 (ONNX)	18
5.5.2. Sistema por divisiones con carga perezosa y evicción	18
5.5.3. Frontend, PWA y despliegue en producción	18
6. Experimentos y resultados	20
6.1. Comparación de modelos	20
6.2. Eficiencia de datos y empate con la línea base	20
6.3. Los datos sintéticos degradan el desempeño	21
6.4. Hallazgo central: el corpus es original	21
6.5. Validación por división	22
6.6. Rendimiento y tiempos en producción	22
6.7. Significancia estadística	23
7. Discusión	25
7.1. «El dato supera a la arquitectura»	25
7.2. Similitud no es plagio	25
7.3. Limitaciones declaradas	25

7.4. Consideraciones éticas e integridad académica	26
7.5. Sobre la reproducibilidad y la integridad de las cifras	26
8. Conclusiones	27
8.1. Verificación de las hipótesis	27
8.2. Cumplimiento de los objetivos	27
8.3. Aportaciones	27
8.4. Dificultades y aprendizajes	28
Referencias	29
A. Anexos	31
A.1. Manual de usuario del sistema	31
A.2. Reproducibilidad	31
A.3. Números canónicos y números prohibidos	32
A.4. Inventario de experimentos	32

Índice de figuras

4.1. Distribución del corpus por división. La división CSH concentra más de la mitad de las tesis, lo que explica el mayor costo de su índice (Capítulo 6).	11
4.2. Proyección t-SNE de los <i>embeddings</i> de las tesis de CBI, coloreadas por área académica. Las áreas forman agrupamientos laxos que se <i>solapan</i> ampliamente: es la primera señal visual de que la cercanía semántica entre tesis es, en buena medida, afinidad temática y no copia.	12
4.3. Idioma del contenido del corpus CBI (muestreo de 38,879 fragmentos). El predominio del español con una fracción no despreciable de inglés motiva el uso de un modelo multilingüe.	13
5.1. Arquitectura de dos etapas: recuperar candidatos (rápido) y clasificarlos (preciso). .	16
5.2. Modo 2 (Buscar en el corpus): selección de división, búsqueda por fragmento o tesis completa, número de candidatos y opción de corpus científico externo. El aviso recuerda que la similitud alta no implica plagio.	17
5.3. Capa federada: el fragmento se traduce, se buscan obras externas, se verifica en inglés y el LLM explica la coincidencia. La comparación es contra texto completo (acceso abierto) o contra el <i>abstract</i> (obra cerrada).	18
5.4. Sistema por divisiones. Cada división tiene sus propios artefactos; solo la activa reside en memoria, cargándose de forma perezosa y liberándose al cambiar.	18
5.5. Interfaz del sistema (Modo 1: comparar dos textos). A la izquierda, la navegación entre modos e información; arriba, la selección de clasificador y el árbitro LLM; el aviso recuerda que la similitud alta puede ser bibliografía o <i>boilerplate</i> , no plagio. . .	19
6.1. F1 de los modelos por conjunto de prueba. La F1 baja hacia los conjuntos más realistas; el AUROC (no mostrado) se mantiene, lo que indica un test más difícil, no un peor modelo.	21
6.2. Matriz de confusión de BETO v3 sobre <code>test_v3_limpio</code> (38 pares). De 9 positivos reales detecta 8 (un falso negativo) y comete 2 falsos positivos: precisión 0.80, <i>recall</i> 0.889 y $F1 = 0.842$	22
6.3. Progresión del afinamiento de BETO. Las versiones con datos humanos (v3, v8a, verde) superan a las sintéticas (v4–v7, naranja); ninguna ampliación sintética rebasa la línea del <i>gold</i> humano de v3.	23
6.4. Similitud media intra- e inter-área (experimento E-2). La diagonal (misma área) es mayor que fuera de ella, pero el solapamiento entre áreas distintas es considerable (~ 0.62 – 0.69): confirma que la similitud es afinidad temática, y justifica que un modelo por dominio no aporte.	24
6.5. Tiempo de análisis por división. El costo crece con el tamaño del corpus (CSH, 10.7M de fragmentos), dominado por la capa de recuperación léxica y de carga única. . . .	24

A.1. Página de inicio del sistema: acceso, divisiones (CBI, CBS, CSH) y datos del corpus, en escritorio y en su versión móvil responsiva.	32
A.2. Detector en su versión móvil (PWA instalable): navegación apilada, selección de clasificador y aviso de similitud. El escudo institucional conserva su proporción.	33
A.3. Módulo «Cómo funciona»: el sistema explica su propia arquitectura al usuario, del documento al veredicto, incluyendo el papel opcional del LLM como árbitro.	34
A.4. Módulo de ejemplos con casos de prueba, y la búsqueda en el corpus (Modo 2) en su versión móvil responsiva.	35

Índice de tablas

4.1.	Composición del corpus TESIUAMI por división.	10
4.2.	Conjuntos de prueba y su propósito.	12
4.3.	Afinamiento de BETO sobre <code>test_v3_limpio</code> (38 pares). Las versiones sintéticas no superan al <i>gold</i> humano de v3.	14
4.4.	Requerimientos del asesor y su atención (síntesis).	14
6.1.	Desempeño (F1 / AUROC) por conjunto de prueba. Cada columna es un conjunto distinto; los valores no son comparables entre columnas.	20
6.2.	F1 e intervalo de confianza al 95 % (<i>bootstrap</i> , 2,000 re-muestras) sobre <code>test_v3_limpio</code> (38 pares). Los intervalos son <i>anchos</i> por el tamaño pequeño del conjunto y se solapan ampliamente.	21
6.3.	Tiempo de análisis de una tesis completa (164 páginas) por división y modo.	23
A.1.	Números canónicos (válidos) y prohibidos (descartados).	33

Lista de acrónimos

Acrónimo	Significado
AUROC	Área bajo la curva ROC (<i>Area Under the ROC Curve</i>)
BERT	<i>Bidirectional Encoder Representations from Transformers</i>
BETO	BERT pre-entrenado en español (<i>Spanish BERT</i>)
BM25	<i>Best Matching 25</i> , función de recuperación léxica
CBI	División de Ciencias Básicas e Ingeniería
CBS	División de Ciencias Biológicas y de la Salud
CSH	División de Ciencias Sociales y Humanidades
ECE	Error de calibración esperado (<i>Expected Calibration Error</i>)
F1	Media armónica de precisión y <i>recall</i>
FAISS	<i>Facebook AI Similarity Search</i>
GCP	<i>Google Cloud Platform</i>
HNSW	<i>Hierarchical Navigable Small World</i> , índice de vecinos aproximados
IC95 %	Intervalo de confianza al 95 %
ICL	Aprendizaje en contexto (<i>In-Context Learning</i>)
int8	Cuantización a enteros de 8 bits
IVFPQ	<i>Inverted File with Product Quantization</i>
LLM	Modelo de lenguaje de gran escala (<i>Large Language Model</i>)
MiniLM	Modelo compacto de <i>embeddings</i> de oraciones
ONNX	<i>Open Neural Network Exchange</i>
PLN	Procesamiento del lenguaje natural
PWA	Aplicación web progresiva (<i>Progressive Web App</i>)
RRF	Fusión recíproca de rangos (<i>Reciprocal Rank Fusion</i>)
TF-IDF	<i>Term Frequency–Inverse Document Frequency</i>
XLM-R	<i>XLM-RoBERTa</i> , modelo multilingüe

Capítulo 1

Introducción

1.1. Motivación y contexto

La paráfrasis es la re-expresión de una idea con palabras distintas conservando su significado. En el ámbito académico, distinguir una paráfrasis legítima (con su cita) de un plagio parafraseado es una tarea difícil incluso para revisores humanos, y crítica para la integridad de los trabajos de titulación. Los sistemas comerciales de detección de similitud (Turnitin, iThenticate) se apoyan en gran medida en la coincidencia léxica y tienen dificultades con la reformulación semántica profunda.

La irrupción de los modelos de lenguaje tipo Transformer —BERT y sus variantes en español (BETO) y multilingües (XLM-RoBERTa)— y de los modelos de lenguaje de gran escala (LLM) ha cambiado el panorama: hoy es posible representar el significado de un texto en un espacio vectorial y comparar pares con un clasificador que «lee» ambos a la vez. Este proyecto retoma esa oportunidad sobre un caso real y cercano: el corpus de tesis **TESIUAMI** de la Unidad Iztapalapa.

1.2. Planteamiento del problema

El trabajo previo de David Luna [1] construyó, para la misma unidad, un detector de paráfrasis basado en redes neuronales convolucionales y recurrentes con *embeddings* estáticos (Word2Vec/FastText), reportando un F1 alto sobre un corpus algorítmicamente balanceado. Quedaban abiertas varias preguntas: ¿los modelos contextuales modernos (BETO, XLM-R) y los LLM mejoran esa detección?, ¿cuánto dato humano anotado se necesita realmente?, ¿los datos sintéticos ayudan?, y —de fondo— ¿existe de verdad plagio parafraseado entre las tesis de la unidad, o la similitud observada es afinidad temática? El problema es, por tanto, doble: *construir* un detector robusto y *medirlo con honestidad* sobre datos realistas.

1.3. Hipótesis

- H1.** Los modelos contextuales afinados (BETO, XLM-R) y su ensamble detectan paráfrasis en español mejor o igual que la línea base con *embeddings* estáticos, con mucho menos dato anotado (*eficiencia de datos*).
- H2.** El aumento de datos sintéticos (paráfrasis generadas por LLM o por retro-traducción) *no* mejora, y puede degradar, la detección de paráfrasis humana real.
- H3.** Gran parte de la «similitud» entre tesis de un mismo dominio es afinidad temática y no plagio; la copia parafraseada real es escasa.

1.4. Objetivos

1.4.1. Objetivo general

Diseñar, implementar y evaluar —con un protocolo estadísticamente honesto— un sistema de detección de paráfrasis y copia sobre el corpus de tesis TESIAMI, basado en modelos de lenguaje contextuales y LLM, y dejarlo operativo en producción.

1.4.2. Objetivos particulares

- O1.** Afinar y comparar modelos de detección de paráfrasis en español (BETO, XLM-R, ensamble) frente a líneas base (TF-IDF, BLEU, SVM) y a la tesis previa.
- O2.** Definir un protocolo de evaluación que evite fuga de datos y balanceo artificial, reportando cada métrica con su conjunto de prueba etiquetado e intervalos de confianza.
- O3.** Evaluar el efecto de los datos sintéticos (LLM y retro-traducción) sobre la detección de paráfrasis humana.
- O4.** Construir un sistema de doble modo (clasificación de pares y análisis de documento completo) con recuperación híbrida sobre el corpus real de las tres divisiones.
- O5.** Integrar un corpus científico externo (federado) y desplegar el sistema en producción de forma reproducible.

1.5. Metodología (resumen)

El trabajo siguió un ciclo iterativo semana a semana: extracción y limpieza del corpus, construcción de conjuntos de prueba de dificultad creciente, afinamiento sucesivo de modelos, evaluación con intervalos de confianza, y desarrollo incremental del sistema hasta su despliegue. Cada afirmación cuantitativa se somete a un *encuadre honesto* (Capítulo 4) y fue objeto de una auditoría independiente.

1.6. Justificación

El proyecto aporta (i) evidencia empírica sobre la eficiencia de datos de los modelos contextuales frente al aumento sintético en un problema real en español; (ii) un hallazgo relevante para la unidad —la originalidad de su corpus de tesis—; y (iii) una herramienta funcional, desplegada y reproducible, útil para asesores y comités de titulación.

1.7. Contribuciones

Las contribuciones de este trabajo son:

- C1.** Un **protocolo de evaluación honesto** para detección de paráfrasis que evita la fuga de datos y el balanceo artificial, y que reporta cada métrica con su conjunto de prueba etiquetado e intervalos de confianza.
- C2.** **Evidencia empírica de eficiencia de datos:** los modelos contextuales igualan a la línea base previa con órdenes de magnitud menos dato anotado, y los datos sintéticos no ayudan.

- C3.** Un **hallazgo sobre el corpus institucional**: mediante búsqueda exhaustiva se muestra que el corpus de tesis es original, con copia parafraseada prácticamente nula entre trabajos.
- C4.** Un **sistema funcional, desplegado y reproducible** de detección de paráfrasis y copia sobre las tres divisiones de la unidad, con corpus interno y externo.

1.8. Alcances y limitaciones

El proyecto abarca la construcción, evaluación y despliegue del detector sobre el corpus TESIUA-MI en español (con soporte de recuperación multilingüe). **Queda fuera de alcance**: la detección de texto generado por inteligencia artificial; la verificación cross-lingüe directa (los documentos en inglés se procesan por traducción automática); y la anotación por más de un evaluador (el conjunto de referencia lo anotó el propio autor, lo que se declara como limitación). Estas fronteras se retoman en el Capítulo 7.

1.9. Organización del documento

El Capítulo 2 presenta los antecedentes teóricos; el Capítulo 3, el estado del arte y la tesis base; el Capítulo 4, la metodología y el protocolo honesto de evaluación; el Capítulo 5, el diseño e implementación del sistema; el Capítulo 6, los experimentos y resultados; el Capítulo 7, la discusión; y el Capítulo 8, las conclusiones.

Capítulo 2

Antecedentes

Este capítulo reúne los fundamentos teóricos necesarios para el resto del documento. Se parte del procesamiento del lenguaje natural y de la definición precisa de la tarea de detección de paráfrasis; se recorre la evolución de las representaciones de texto —de los métodos estáticos a los modelos tipo Transformer—; se describen las técnicas de recuperación de información vectorial y léxica que hacen viable buscar en millones de fragmentos; se introducen los modelos de lenguaje de gran escala; y se cierra con las métricas y las herramientas estadísticas con que se evalúa el sistema.

2.1. Procesamiento del lenguaje natural

El procesamiento del lenguaje natural (PLN) es el área de la inteligencia artificial que estudia cómo las computadoras pueden representar, comprender y generar lenguaje humano. Entre sus tareas clásicas están la clasificación de texto, el reconocimiento de entidades, la traducción automática, la respuesta a preguntas y la detección de similitud semántica. La detección de paráfrasis pertenece a esta última familia: dados dos textos, decidir si expresan el mismo significado.

Un obstáculo central del PLN es que el lenguaje es *ambiguo y redundante*: una misma idea admite muchas formulaciones (sinónimos, cambios de orden, voz activa/pasiva, nominalizaciones), y formulaciones parecidas pueden significar cosas distintas. Por ello, comparar textos por sus palabras exactas es insuficiente y se requiere capturar su *significado*.

2.2. La tarea de detección de paráfrasis

Una **paráfrasis** es la re-expresión del contenido de un texto con palabras y estructura distintas, conservando su significado. La **detección de paráfrasis** se formula como un problema de clasificación binaria: dada una pareja de textos (a, b) , predecir si b es una paráfrasis de a (clase positiva) o no (clase negativa).

Es indispensable distinguir tres conceptos que suelen confundirse:

- **Paráfrasis legítima**: reformular una idea ajena *y citar la fuente*. Es una práctica académica correcta.
- **Cita textual**: reproducir literalmente un fragmento entrecomillado y atribuido. También es correcta.
- **Plagio parafraseado**: reformular una idea ajena *sin* atribuirle, presentándola como propia. Es una falta a la integridad académica.

La consecuencia metodológica es clara y guía todo el proyecto: *la similitud entre dos textos no implica plagio*. Dos tesis del mismo tema comparten vocabulario, definiciones y bibliografía; ese solapamiento es afinidad temática, no copia. Un detector responsable debe separar la coincidencia superficial de la re-expresión encubierta, y presentar la similitud como un indicio para revisión humana, nunca como una acusación automática.

2.3. De las representaciones estáticas a los Transformers

Para que un modelo compare significados, primero debe *representar* el texto como vectores numéricos. La forma de construir esos vectores ha evolucionado radicalmente.

2.3.1. Representaciones estáticas: TF-IDF, Word2Vec y FastText

Las primeras representaciones fueron *dispersas* y basadas en frecuencia. En **TF-IDF** (*Term Frequency–Inverse Document Frequency*) cada documento es un vector del tamaño del vocabulario, donde cada componente pondera lo frecuente que es una palabra en el documento frente a lo rara que es en la colección [12]. Es interpretable y sorprendentemente competitivo, pero ignora el orden y los sinónimos.

Los *embeddings* **estáticos** —Word2Vec [8] y FastText [9]— aprenden un vector *denso* por palabra a partir de sus contextos, de modo que palabras semánticamente cercanas quedan próximas en el espacio. FastText, además, compone la palabra a partir de sub-cadenas de caracteres, lo que le permite representar términos no vistos. Su limitación es que asignan *un solo* vector a cada palabra: no distinguen «banco» (asiento) de «banco» (institución). Este fue el tipo de representación empleado en la tesis base [1].

2.3.2. Transformers, BERT y sus variantes en español y multilingües

El Transformer [2] introdujo el mecanismo de *atención*, que permite a cada palabra «mirar» a todas las demás de la oración y ponderar su relevancia. Sobre esta arquitectura, **BERT** [3] propuso pre-entrenar un modelo profundo de manera auto-supervisada (prediciendo palabras enmascaradas) sobre grandes corpus, para luego *afinarlo* (*fine-tuning*) en tareas concretas con relativamente pocos datos. La clave es que BERT produce *embeddings contextuales*: el vector de una palabra depende de su oración, resolviendo la ambigüedad de las representaciones estáticas.

Para el español se usa **BETO** [4], un BERT pre-entrenado sobre un gran corpus en español; y para escenarios multilingües, **XLNet-RoBERTa** (XLM-R) [5], entrenado sobre cien idiomas, que permite comparar textos entre lenguas sin traducir. Ambos son piezas centrales de este trabajo.

2.3.3. Bi-codificadores frente a codificadores cruzados

Existen dos maneras de usar estos modelos para comparar pares de textos, con un compromiso entre velocidad y precisión:

- Un **bi-codificador** (*bi-encoder*) codifica cada texto por separado en un vector; la similitud es entonces una simple operación (coseno) entre vectores. Es muy *rápido* y permite pre-calcular millones de vectores e indexarlos, pero pierde precisión porque nunca compara los dos textos «juntos». Se usa para *recuperar* candidatos (aquí, con el modelo MiniLM [7]).
- Un **codificador cruzado** (*cross-encoder*) recibe los dos textos *concatenados* y los procesa a la vez, atendiendo a las interacciones entre ambos; es más *preciso* pero costoso, pues no se puede pre-calcular. Se usa para *clasificar* el par final.

La arquitectura del sistema (Capítulo 5) explota este compromiso: bi-codificador para recuperar, codificador cruzado para decidir.

2.4. Recuperación de información vectorial

Analizar una tesis completa contra un corpus de millones de fragmentos exige *recuperar* primero un puñado de candidatos plausibles, porque clasificar todos los pares posibles es inviable.

2.4.1. Búsqueda por similitud aproximada: FAISS, HNSW e IVFPQ

La biblioteca **FAISS** [10] implementa búsqueda de vecinos más cercanos sobre vectores densos. Como la búsqueda exacta es cara a gran escala, se usan índices *aproximados*: **HNSW** [11] construye un grafo navegable de «mundo pequeño» que encuentra vecinos en tiempo casi logarítmico con alta exactitud, a costa de memoria; e **IVFPQ** (*Inverted File with Product Quantization*) comprime los vectores para reducir drásticamente la memoria, a costa de algo de exactitud. El sistema usa HNSW en la división más consultada e IVFPQ en las de mayor tamaño.

2.4.2. Recuperación léxica: BM25

La búsqueda semántica puede pasar por alto una *copia literal* con vocabulario poco común. Para cubrir ese caso se emplea **BM25** [12], una función de recuperación léxica que puntúa documentos por la coincidencia de términos ponderada por su rareza. BM25 y la búsqueda semántica son complementarios: uno atrapa la copia con las mismas palabras, el otro la reformulación con palabras distintas.

2.4.3. Fusión de rankings: Reciprocal Rank Fusion

Para combinar ambas listas de candidatos sin tener que calibrar pesos entre puntajes de naturaleza distinta, se usa **RRF** (*Reciprocal Rank Fusion*) [13], que suma el inverso del rango de cada documento en cada lista. Un documento bien posicionado en varias listas asciende, lo que produce una combinación robusta.

2.5. Modelos de lenguaje de gran escala e *in-context learning*

Los modelos de lenguaje de gran escala (LLM), como la familia Llama [17], son modelos generativos con miles de millones de parámetros capaces de resolver tareas a partir de instrucciones en lenguaje natural. Mediante *aprendizaje en contexto* (*in-context learning*, ICL) resuelven una tarea nueva a partir de cero, uno o pocos ejemplos en el propio *prompt*, sin re-entrenar. En este proyecto los LLM se emplean de forma *acotada*: como «árbitro» en la zona de incertidumbre del clasificador y como generador de explicaciones legibles («¿por qué se parecen estos textos?»), no como el detector principal.

2.6. Métricas y evaluación

2.6.1. Precisión, *recall*, F1 y AUROC

En clasificación binaria, la **precisión** es la fracción de positivos predichos que son correctos, y el **recall** la fracción de positivos reales que se detectan. La **F1** es su media armónica y resume

el equilibrio entre ambos. El **AUROC** (área bajo la curva ROC) mide la capacidad de *ordenar* correctamente positivos por encima de negativos independientemente del umbral, y por ello es especialmente informativo cuando la proporción de positivos es baja.

2.6.2. Intervalos de confianza y significancia estadística

Un valor de F1 sobre un conjunto de prueba pequeño es una *estimación* con incertidumbre. Para cuantificarla se usa *bootstrap*: se re-muestra el conjunto de prueba con reemplazo muchas veces y se calcula la métrica en cada re-muestra, obteniendo un **intervalo de confianza al 95 % (IC95 %)**. Si los intervalos de dos modelos se solapan, su diferencia *no es estadísticamente significativa*. Esta herramienta es la que permite afirmar, con rigor, que dos modelos «empatan» (Capítulo 6).

2.6.3. Calibración de probabilidades

Un modelo está **calibrado** si, cuando afirma «80 % de probabilidad», acierta el 80 % de las veces. La *calibración de temperatura* divide las salidas del modelo por un escalar T ajustado para alinear confianza y acierto, y el **ECE** (*Expected Calibration Error*) mide cuánto se desvía de la calibración perfecta. La calibración es importante para fijar umbrales de decisión sensatos y para la cuantización a int8, que altera ligeramente las salidas del modelo.

Capítulo 3

Estado del arte

Este capítulo sitúa el trabajo frente a lo publicado: los corpus de paráfrasis de referencia, la tesis base que antecede directamente a este proyecto, los enfoques modernos con modelos contextuales y LLM, el papel de los datos sintéticos y los sistemas comerciales de detección de similitud.

3.1. Corpus de paráfrasis

La investigación en paráfrasis se ha apoyado en varios corpus de referencia. El **MRPC** (*Microsoft Research Paraphrase Corpus*) [16] reúne pares de oraciones de noticias anotadas como paráfrasis o no. El conjunto de preguntas duplicadas de Quora (**QQP**) aporta pares de preguntas del mundo real. Un avance importante fue **PAWS** (*Paraphrase Adversaries from Word Scrambling*) [15], que genera pares *adversarios* con alto solapamiento léxico pero distinto significado (por reordenamiento de palabras), obligando a los modelos a ir más allá de la coincidencia superficial; su extensión multilingüe **PAWS-X** [14] incluye español y se emplea en este trabajo para validar los modelos.

En el ámbito institucional, la tesis base construyó el corpus **CBI-M-00-21** a partir de tesis de la División de Ciencias Básicas e Ingeniería de la unidad; este proyecto retoma y amplía esa línea con el corpus **TESIUAMI**, extendido a las tres divisiones (Capítulo 4).

3.2. La tesis base: detección de paráfrasis con aprendizaje automático

El antecedente directo de este trabajo es la tesis de maestría de David Luna [1], desarrollada en la misma unidad y con el mismo asesor. En ella se construyó un detector de paráfrasis para el corpus CBI-M-00-21 basado en *embeddings* estáticos (Word2Vec/FastText) y arquitecturas de redes neuronales convolucionales y recurrentes (CNN, LSTM) combinadas en un ensamble, reportando un valor de F1 alto sobre un corpus balanceado al 50 %.

Este proyecto se diferencia y complementa a la tesis base en tres aspectos: (i) emplea modelos *contextuales* (BETO, XLM-R) y LLM en lugar de *embeddings* estáticos; (ii) somete la evaluación a un protocolo que evita la fuga de datos y el balanceo artificial, lo que —como se verá— reencuadra la interpretación de las cifras; y (iii) lleva el detector hasta un sistema desplegado sobre las tres divisiones. Un resultado central del presente trabajo es que, medido cabeza a cabeza sobre el mismo conjunto de prueba, el mejor modelo contextual *empata* con la línea base dentro del intervalo de confianza: el aporte no es superar su F1, sino lograrlo con mucho menos dato anotado.

3.3. Detección de paráfrasis con modelos contextuales y LLM

Tras BERT [3], el estándar para detección de paráfrasis pasó a ser el *fine-tuning* de codificadores cruzados sobre pares etiquetados, con resultados superiores a los métodos basados en *embeddings* estáticos en los corpus de referencia. Arquitecturas recientes combinan bi-codificadores y codificadores cruzados para equilibrar velocidad y precisión [7]. Con la llegada de los LLM, el aprendizaje en contexto permite abordar la tarea con pocos o ningún ejemplo; sin embargo, su costo y su variabilidad hacen que, en producción, sigan siendo preferibles los modelos afinados —reservando el LLM para funciones de apoyo (arbitraje y explicación), como en este trabajo.

3.4. Datos sintéticos para el procesamiento del lenguaje

Ante la escasez de datos anotados, una estrategia común es *generar* paráfrasis sintéticas: mediante LLM (por ejemplo, generación guiada por *prompt*) o mediante **retro-traducción** (traducir a otro idioma y de vuelta, aprovechando que la traducción reformula). Estas técnicas amplían la cantidad de datos, pero introducen un *sesgo de distribución*: el texto sintético tiende a un estilo uniforme y detectable, distinto del humano. Uno de los aportes empíricos de este trabajo (Capítulo 6) es mostrar que, para detectar paráfrasis *humana* real, el aumento sintético no ayuda e incluso degrada el desempeño.

3.5. Sistemas comerciales de detección de similitud

Herramientas como Turnitin e iThenticate son el estándar de facto en la revisión de originalidad. Operan principalmente por *coincidencia léxica* contra grandes repositorios: son eficaces detectando copia literal, pero tienen dificultades ante la reformulación semántica profunda y no distinguen entre coincidencia por afinidad temática y copia encubierta. El presente sistema se posiciona como complemento semántico y transparente: recupera la fuente candidata, la clasifica con un modelo que «lee» ambos textos y presenta la evidencia para revisión humana, contando solo lo confirmado en el puntaje.

Capítulo 4

Metodología

Este capítulo describe cómo se construyó y evaluó el detector. Se detalla el corpus, los modelos comparados, y —de manera central— el *protocolo de evaluación honesto* que distingue a este trabajo: un conjunto de reglas para que cada cifra sea defendible. Se describen también el afinamiento sucesivo de modelos, la calibración, el proceso iterativo de desarrollo con los requerimientos del asesor, y la auditoría independiente a la que se sometió el proyecto.

4.1. El corpus TESIUAMI

4.1.1. Extracción y limpieza

El corpus se construyó a partir de los archivos PDF de las tesis de la unidad, almacenados en una base de datos MongoDB. De cada documento se extrajo el texto y se filtraron las secciones no informativas para la tarea (portadas, actas, índices y listas de referencias), que de otro modo introducen coincidencias espurias por su carácter repetitivo e institucional (*boilerplate*).

4.1.2. Las tres divisiones: CBI, CBS y CSH

Mientras que la tesis base se limitó a la División de Ciencias Básicas e Ingeniería, este trabajo amplió el corpus a las **tres divisiones** de la unidad, con un total de **21,128 tesis** indexadas (Tabla 4.1).

Tabla 4.1: Composición del corpus TESIUAMI por división.

División	Tesis	Fragmentos
CBI · Ciencias Básicas e Ingeniería	4,970	2.28 M
CBS · Ciencias Biológicas y de la Salud	5,416	2.30 M
CSH · Ciencias Sociales y Humanidades	10,742	10.70 M
Total	21,128	15.3 M

4.1.3. Fragmentación por ventanas deslizantes

Como una tesis es demasiado larga para compararse como un todo, cada documento se corta en *fragmentos* mediante ventanas deslizantes de 400 caracteres con un desplazamiento (*stride*) de 200, de modo que las ventanas se solapan y ninguna coincidencia queda partida entre dos fragmentos.




Figura 4.1: Distribución del corpus por división. La división CSH concentra más de la mitad de las tesis, lo que explica el mayor costo de su índice (Capítulo 6).

Cada fragmento se vectoriza y se indexa; el número total de fragmentos por división aparece en la Tabla 4.1.

4.1.4. Idioma del corpus

Aunque las tesis están mayoritariamente en español, una fracción incluye contenido en inglés (resúmenes, citas, terminología). Un muestreo de 38,879 fragmentos de CBI (Figura 4.3) arroja 86.1 % de contenido en español, 6.0 % en inglés y 7.3 % en otras lenguas, con cerca del 30 % de las tesis conteniendo algo de inglés. Este dato *justifica* emplear un modelo **multilingüe** (XLM-R), capaz de comparar fragmentos entre lenguas sin traducir, en lugar de uno exclusivamente en español.

4.2. Modelos evaluados

Se compararon modelos de tres familias: (i) **contextuales afinados** —BETO, XLM-R y su *ensamble* por promedio de probabilidades—; (ii) **líneas base** clásicas —TF-IDF, BLEU y una máquina de vectores de soporte (SVM) sobre *embeddings*—; y (iii) un **bi-codificador** (MiniLM) para la etapa de recuperación. Los LLM se usaron solo como apoyo (arbitraje y explicación).

4.3. Protocolo de evaluación honesto

El eje metodológico del trabajo es reportar cada métrica de forma que resista el escrutinio. Ello exigió corregir dos vicios frecuentes.

4.3.1. Fuga de datos y balanceo artificial

Se detectaron y descartaron cifras infladas por dos causas. La **fuga de datos** ocurre cuando pares del conjunto de prueba aparecen —exacta o casi exactamente— en el de entrenamiento; se corrigió con de-duplicación y con un *group-split* que garantiza que ningún fragmento de una misma tesis caiga a la vez en entrenamiento y prueba. El **balanceo artificial** ocurre cuando el conjunto de prueba tiene 50 % de positivos, proporción irreal que infla la F1 frente a la prevalencia baja del mundo real. Como consecuencia de aplicar estas correcciones, varias cifras iniciales muy altas




Figura 4.2: Proyección t-SNE de los *embeddings* de las tesis de CBI, coloreadas por área académica. Las áreas forman agrupamientos laxos que se *solapan* ampliamente: es la primera señal visual de que la cercanía semántica entre tesis es, en buena medida, afinidad temática y no copia.

resultaron *inválidas* y quedaron explícitamente prohibidas en el reporte (véase el Anexo A); las que se conservan son las que sobreviven al protocolo.

4.3.2. El «número doble/triple»: conjuntos de prueba etiquetados

Ninguna métrica se reporta sola: siempre acompañada del conjunto sobre el que se midió. Se definieron tres conjuntos de prueba de dificultad creciente (Tabla 4.2): `test_v3_limpio` (histórico, fácil), `test_v4` (robusto) y `test_v5` (realista y difícil, con 33 % de positivos y negativos adversarios verificados a mano). Una misma métrica sube o baja según el conjunto; declararlo evita comparaciones engañosas.

Tabla 4.2: Conjuntos de prueba y su propósito.

Conjunto	Pares	% positivos	Propósito
<code>test_v3_limpio</code>	38	24 %	Histórico, comparable con la línea base
<code>test_v4</code>	109	52 %	Robusto, revela la dificultad real
<code>test_v5</code>	225	33 %	Realista, prevalencia y negativos difíciles




Figura 4.3: Idioma del contenido del corpus CBI (muestreo de 38,879 fragmentos). El predominio del español con una fracción no despreciable de inglés motiva el uso de un modelo multilingüe.

4.3.3. Intervalos de confianza y significancia

Sobre cada conjunto se calculan intervalos de confianza al 95 % por *bootstrap*. La comparación con la línea base se hace cabeza a cabeza sobre el mismo conjunto: si los intervalos se solapan, la diferencia no es significativa. Este es el fundamento de la afirmación —central en el Capítulo 6— de que el mejor modelo *empata* con la tesis previa.

Como comprobación complementaria se realizó **validación cruzada** con *group-split* por tesis (ningún fragmento de una misma tesis en entrenamiento y en validación a la vez). Los pliegues evaluados mostraron un desempeño *estable*: F1 de validación en torno a 0.82–0.88 y F1 sobre `test_v4` ≈ 0.79 —consistente con el modelo desplegado (0.791)— con baja varianza ($\sigma \approx 0.014$). Esto respalda que las cifras reportadas no dependen de un particionado afortunado. Se caracterizó además un colapso ocasional de XLM-R en algún pliegue (recall nulo), mitigado con reintentos, que se documenta como comportamiento a vigilar.

4.4. Afinamiento de modelos (*fine-tuning*)

Se afinó BETO de forma sucesiva a lo largo de ocho versiones, variando la fuente y el tipo de datos de entrenamiento (Tabla 4.3). El experimento es un estudio controlado del efecto de los datos: partiendo de un conjunto pequeño de pares anotados por humanos (*gold*), se probó ampliarlo con paráfrasis generadas por LLM, con retro-traducción y con combinaciones. El resultado es consistente: *ninguna* ampliación sintética supera al *gold* humano, y algunas lo degradan.

* BETO v8a alcanza 0.889 en GPU pero es frágil entre *hardware* (0.818 en CPU) y su mejora sobre v3 equivale a un solo falso positivo menos sobre un test pequeño; se reporta como ≈ 0.82 –0.89, dentro del intervalo de v3.

4.5. Calibración

Las salidas de un clasificador no son directamente probabilidades fiables. Se aplicó *calibración de temperatura* por modelo: para XLM-R se ajustó T de modo que el error de calibración esperado (ECE) bajara de 0.246 a 0.076. La cuantización a int8 (que acelera la inferencia) altera ligeramente las salidas, por lo que exigió una *re-calibración* propia (T distinta a la de la versión de punto flotante).

Tabla 4.3: Afinamiento de BETO sobre `test_v3_limpio` (38 pares). Las versiones sintéticas no superan al *gold* humano de v3.

Versión	Datos de entrenamiento	F1
BETO v1	<i>gold</i> inicial pequeño	0.383
BETO v2	<i>gold</i> ampliado	0.514
BETO v3	144 pares <i>gold</i> humanos	0.842
BETO v4	5,000 fragmentos consecutivos	0.750
BETO v5	500 pares generados por LLM	0.600
BETO v6	1,004 pares (retro-traducción + LLM)	0.783
BETO v7	2,000 pares de retro-traducción	0.643
BETO v8a	155 (<i>gold</i> + 11 humanos)	0.889*

La calibración es lo que permite fijar un umbral de decisión sensato y una zona de incertidumbre donde interviene el árbitro.

4.6. Desarrollo iterativo del proyecto y requerimientos del asesor

El proyecto se desarrolló de forma *iterativa*, semana a semana, en ciclos de: construcción o refinamiento del corpus y de los conjuntos de prueba, afinamiento y evaluación de modelos, y desarrollo incremental del sistema hasta su despliegue. En cada ciclo, el asesor planteó requerimientos concretos que orientaron el avance; la Tabla 4.4 resume los principales y cómo se atendieron.

Tabla 4.4: Requerimientos del asesor y su atención (síntesis).

Bloque	Requerimiento y atención
Modelos y evaluación	SVM con distintos <i>kernels</i> ; evaluación con igual N , réplicas y determinismo; matrices de confusión; <i>pipeline</i> RAG (diagnosticado).
Protocolo (R2–R3)	Validación cruzada, análisis del <i>split</i> , PAWS-X; framework unificado de evaluación.
Backbone (R5)	Selección de XLM-R como <i>backbone</i> de producción, calibrado.
Índice (R8)	Índice de recuperación al 100 % del corpus.
Explicabilidad (R8.1)	Módulo que resalta copia literal y frases parafraseadas.
Arquitecturas (R8.3)	Comparativa de índices de búsqueda (HNSW gana).
Velocidad (R9.1)	Cuantización int8 y análisis de arquitectura de despliegue.
Cross-lingüe (R9.2)	Prototipo de corpus científico externo (federado).
Costos y modos (R10.1–R10.2)	Análisis de costo de GPU y de ensamble secuencial.
Comparación de fuentes (R10.3–R10.4)	Comparación 1 vs 1 y contra la fuente web.
OCR (R10.5)	Recuperación de texto de tesis escaneadas (demostrada en un lote).

4.7. Auditoría independiente

Para reforzar la integridad de las cifras, el proyecto se sometió a una *auditoría adversaria* independiente (a la mitad del desarrollo y de nuevo al cierre), que revisó los resultados en busca de fugas de datos, balanceos y afirmaciones no sustentadas. La auditoría fijó la lista de *números canónicos* (los que se sostienen, con su conjunto de prueba) y la de *números prohibidos* (los descartados por fuga o balanceo). El presente reporte se ciñe a esa lista; ambas se incluyen en el Anexo [A](#) para trazabilidad.

Capítulo 5

Diseño e implementación del sistema

Este capítulo describe el sistema construido: su arquitectura general, los dos modos de uso, la capa de corpus científico externo y las decisiones de optimización y despliegue que lo hacen operativo en producción.

5.1. Arquitectura general: recuperar $\rightarrow$ clasificar

El sistema se organiza en dos etapas complementarias que resuelven el compromiso entre velocidad y precisión (Figura 5.1). Primero, un **bi-codificador** (MiniLM) representa el texto y *recupera* un puñado de candidatos entre millones de fragmentos, apoyado en índices de vecinos aproximados (HNSW/IVFPQ) y en recuperación léxica (BM25), fusionados por RRF. Después, un **codificador cruzado** cuantizado a int8 (BETO, XLM-R o su ensamble) *clasifica* solo esos pocos candidatos, leyendo ambos textos a la vez. Así, el modelo caro se ejecuta pocas veces y el sistema escala al corpus completo.




Figura 5.1: Arquitectura de dos etapas: recuperar candidatos (rápido) y clasificarlos (preciso).

5.2. Modo 1: clasificación de pares

El primer modo recibe *dos textos* y responde si uno es paráfrasis del otro, con una etiqueta (copia casi literal, paráfrasis, o alta similitud por revisar) y su probabilidad calibrada. La decisión la toma el codificador cruzado cuantizado; en la *zona de incertidumbre* (probabilidad intermedia) puede intervenir un **árbitro** basado en un LLM, que emite un juicio adicional. El modo sirve para verificar un par concreto y para la comparación uno contra uno de dos documentos.

5.3. Modo 2: análisis de documento completo

El segundo modo recibe una tesis completa (texto pegado o PDF) y la analiza contra el corpus interno de la división elegida (Figura 5.2). El usuario elige la *división* del corpus (CBI, CBS o CSH), decide si busca por *fragmento* o por *tesis completa*, y puede activar además el corpus científico externo.

Paráfrasis
SISTEMA V6

PROCESAMIENTO

- Comparar textos
- Buscar en corpus

INFORMACIÓN

- Cómo se usa
- Cómo funciona
- Ejemplos

Detección Inteligente de Paráfrasis
mediante Modelos de Lenguaje de
Gran Escala (LLM)

ALUMNO
Juan Antonio Soria Rodríguez ·
2203041232

ASESOR
Dr. Benjamín Moreno Montiel

PROGRAMA
Proyecto Terminal de Investigación I ·
Lic. Computación

INSTITUCIÓN
UAM Iztapalapa · División CBI · Grupo
CK06

Índice 100% · 2.29M frags (incl. 16
tesis OCR s10) · TESUAMI

Buscar en el corpus · índice 100%

← Inicio · BETO · índice · BM25 · Clasificador · BETO v3 (recall alto — recomendado) · Arbitro LLM

Iniciar sesión · Registrarse · salir

Reporte de similitud. Similitud alta puede ser bibliografía compartida, terminología común o boilerplate.

Fragmento de texto · Tesis completa

División del corpus · CBI · Ciencias Básicas e Ingeniería · Elige la división de tesis contra la que comparar.

Buscar un fragmento contra todo el corpus

Pega aquí un fragmento sospechoso...

Buscar · candidatos (k) 15 · también corpus científico externo (OpenAlex)

La primera búsqueda carga el índice (~1-2 min).

Figura 5.2: Modo 2 (Buscar en el corpus): selección de división, búsqueda por fragmento o tesis completa, número de candidatos y opción de corpus científico externo. El aviso recuerda que la similitud alta no implica plagio.

5.3.1. Recuperación híbrida: HNSW + BM25 + RRF

Cada fragmento del documento busca sus candidatos por dos vías: la **semántica** (HNSW/IVFPQ sobre los *embeddings*) y la **léxica** (BM25). Ambas listas se fusionan por RRF, combinando la fuerza de cada una: la semántica atrapa la reformulación y la léxica la copia con vocabulario poco común. Los candidatos fusionados pasan al codificador cruzado.

5.3.2. Reporte estilo «informe de similitud»

El resultado es un reporte legible: un porcentaje global de similitud, el detalle por secciones, las fuentes principales, tarjetas de evidencia con el fragmento y su fuente, y el resaltado sobre el texto original. Un principio de diseño guía el puntaje: el porcentaje *titular* cuenta **solo lo confirmado** por el clasificador (copia o paráfrasis), no la mera similitud alta; el *boilerplate* institucional y la bibliografía compartida se contabilizan aparte y no inflan la cifra. Así se evita alarmar por afinidad temática.

5.4. Corpus científico externo (federado)

Además del corpus interno, el sistema puede comparar contra un corpus científico externo de ~250 millones de obras, consultando **OpenAlex**, **Semantic Scholar** y **Crossref**. Como estos servicios operan en inglés, el fragmento se traduce internamente (es $\rightarrow$ en) y la verificación se hace en-en. Para cada obra se muestra un par de fragmentos (el del documento y el de la fuente), legibles en ambos idiomas y con una explicación generada por el LLM. Cuando la obra es de acceso abierto se descarga su texto completo (con validaciones de seguridad anti-SSRF); cuando es cerrada, la comparación se hace contra su resumen (*abstract*), declarándolo. Los datos externos se atribuyen a sus fuentes conforme a sus licencias (Figura 5.3).




Figura 5.3: Capa federada: el fragmento se traduce, se buscan obras externas, se verifica en inglés y el LLM explica la coincidencia. La comparación es contra texto completo (acceso abierto) o contra el *abstract* (obra cerrada).

5.5. Optimización y despliegue

5.5.1. Cuantización int8 (ONNX)

Para acelerar la inferencia en CPU, los clasificadores se exportaron a ONNX y se cuantizaron a enteros de 8 bits (int8), lo que reduce el tamaño y el tiempo por par a cambio de una degradación mínima y declarada, previa re-calibración de temperatura.

5.5.2. Sistema por divisiones con carga perezosa y evicción

Cada división tiene sus propios índices, metadatos y modelo; como no caben las tres a la vez en memoria, se cargan de forma *perezosa* (solo la división activa) y se *evacúan* (liberan) al cambiar de división. Ello permite servir las tres divisiones con recursos acotados (Figura 5.4).




Figura 5.4: Sistema por divisiones. Cada división tiene sus propios artefactos; solo la activa reside en memoria, cargándose de forma perezosa y liberándose al cambiar.

5.5.3. Frontend, PWA y despliegue en producción

La interfaz es una aplicación web *instalable* (PWA) con los dos modos, el corpus externo y el reporte descargable. El sistema está desplegado en dos entornos: el **canónico** en Google Cloud Platform, con las tres divisiones al 100 %; y una **demonstración** pública en Hugging Face Spaces,

con las divisiones CBI y CBS completas y CSH como muestra (limitación de recursos declarada en la propia página). La Figura 5.5 muestra la interfaz del detector (Modo 1).

Figura 5.5: Interfaz del sistema (Modo 1: comparar dos textos). A la izquierda, la navegación entre modos e información; arriba, la selección de clasificador y el árbitro LLM; el aviso recuerda que la similitud alta puede ser bibliografía o *boilerplate*, no plagio.

Capítulo 6

Experimentos y resultados

Este capítulo presenta los resultados bajo el protocolo honesto del Capítulo 4. Cada cifra se acompaña de su conjunto de prueba; las comparaciones se hacen cabeza a cabeza con intervalos de confianza.

6.1. Comparación de modelos

La Tabla 6.1 resume el desempeño de los modelos contextuales sobre los tres conjuntos de prueba. Se observa el efecto esperado: la F1 baja al pasar a conjuntos más difíciles y realistas, mientras que el AUROC —la capacidad de ordenar— se mantiene estable en torno a 0.81–0.84. La caída de F1 no indica un peor modelo, sino un test más exigente (mayor prevalencia realista y negativos adversarios); por eso nunca se reporta la F1 de un conjunto sin declarar cuál es.

Tabla 6.1: Desempeño (F1 / AUROC) por conjunto de prueba. Cada columna es un conjunto distinto; los valores no son comparables entre columnas.

Modelo	test_v3_limpio (38, fácil)	test_v4 (109, robusto)	test_v5 (225, realista)
BETO v3	0.842 / 0.989	—	0.714 / 0.836
XLM-R v4	0.941 ^r / —	0.812 / 0.839	0.677 / 0.810
Ensamble	0.889 / 0.996	—	0.670 / 0.837

^r Valor de *referencia* sobre el conjunto fácil; el titular honesto de XLM-R es el de `test_v4`.

6.2. Eficiencia de datos y empate con la línea base

Sobre el conjunto histórico comparable, el mejor modelo afinado (BETO v3) alcanza **F1 = 0.842**. La comparación cabeza a cabeza con las líneas base sobre el *mismo* conjunto da valores muy cercanos —TF-IDF 0.842 y FastText 0.818— con **intervalos de confianza al 95 % solapados** (Tabla 6.2): la diferencia *no es estadísticamente significativa*. En otras palabras, el modelo contextual *empata* con la aproximación de la tesis base. El aporte, por tanto, no es superar esa cifra sino la **eficiencia de datos**: BETO v3 la logra con del orden de *decenas* de pares anotados por humanos, frente a los cientos de miles de pares algorítmicos del enfoque previo.

La amplitud de estos intervalos —consecuencia directa de evaluar sobre solo 38 pares— es en sí misma un resultado honesto: con un conjunto tan pequeño, ninguna diferencia entre sistemas




Figura 6.1: F1 de los modelos por conjunto de prueba. La F1 baja hacia los conjuntos más realistas; el AUROC (no mostrado) se mantiene, lo que indica un test más difícil, no un peor modelo.

Tabla 6.2: F1 e intervalo de confianza al 95 % (*bootstrap*, 2,000 re-muestras) sobre `test_v3_limpio` (38 pares). Los intervalos son *anchos* por el tamaño pequeño del conjunto y se solapan ampliamente.

Sistema	F1	IC95 %
BETO v3	0.842	[0.609, 1.000]
TF-IDF + coseno	0.842	[0.600, 1.000]
FastText + coseno	0.818	[0.588, 0.960]

alcanza significancia estadística, y toda afirmación de superioridad debe leerse con cautela.

6.3. Los datos sintéticos degradan el desempeño

El estudio controlado de afinamiento (Tabla 4.3) muestra que *ninguna* ampliación sintética supera al *gold* humano de v3, y que a mayor cantidad de datos sintéticos *uniformes* la precisión empeora: las versiones basadas en generación por LLM (v5) y en retro-traducción pura (v7) presentan los peores valores, con más falsos positivos. La causa es un sesgo de distribución: el modelo aprende el *estilo* del generador —vocabulario uniforme, calcos de traducción— en lugar de la relación semántica de paráfrasis. Es la primera evidencia de la tesis central: el dato humano de calidad supera al volumen sintético.

6.4. Hallazgo central: el corpus es original

Para responder a la pregunta de fondo —¿existe plagio parafraseado entre las tesis?— se realizó una búsqueda amplia de candidatos con el índice semántico (miles de consultas sobre el corpus, bajo un *muestreo declarado* de fragmentos por tesis) y se verificaron manualmente los pares señalados. El resultado es contundente: **no se encontró plagio parafraseado entre tesis distintas**. Al clasificar los pares marcados como positivos, la mayoría resultó ser *boilerplate* institucional (~58 %)




Figura 6.2: Matriz de confusión de BETO v3 sobre `test_v3_limpio` (38 pares). De 9 positivos reales detecta 8 (un falso negativo) y comete 2 falsos positivos: precisión 0.80, *recall* 0.889 y $F1 = 0.842$.

o copia casi literal de bibliografía compartida ($\sim 21\%$); solo una minoría ($\sim 16\%$, apenas tres pares) fue paráfrasis reformulada de una fuente común. La tasa de paráfrasis real entre los candidatos revisados es de aproximadamente **3 %**.

La conclusión es doble: el corpus de tesis de la unidad es, en lo esencial, *original*; y la «similitud» que un detector ingenuo reportaría entre tesis del mismo tema es **afinidad temática, no plagio**. Este hallazgo justifica el principio de diseño de contar solo lo confirmado (Capítulo 5). Debe declararse su alcance: la búsqueda se realizó sobre un *muestreo* del corpus (un tope de fragmentos por tesis), por lo que el resultado es «no se encontró plagio parafraseado *bajo ese muestreo*», no una prueba absoluta de su inexistencia.

6.5. Validación por división

Se evaluó si un modelo especializado en el dominio de cada división (por ejemplo, un modelo afinado con lenguaje de ciencias sociales para CSH) mejora sobre el modelo general. El resultado, medido con intervalos de confianza, fue negativo: el contexto de dominio *no aporta* una mejora significativa sobre el modelo general. Es un resultado negativo honesto que refuerza la tesis central: a esta escala, la palanca es el dato, no la especialización arquitectónica.

6.6. Rendimiento y tiempos en producción

Se midió el tiempo de analizar una tesis completa (164 páginas) contra cada división interna (Tabla 6.3). El cuello de botella en la división mayor (CSH) no es el clasificador (que toma segundos), sino la capa de recuperación léxica (BM25) sobre una matriz de más de diez millones de documentos; y es, sobre todo, un costo de *carga única*: solo la primera tesis de una división paga la carga del índice a memoria, y el mismo documento repetido se resuelve en ~ 1 s gracias a una caché de reportes.




Figura 6.3: Progresión del afinamiento de BETO. Las versiones con datos humanos (v3, v8a, verde) superan a las sintéticas (v4–v7, naranja); ninguna ampliación sintética rebasa la línea del *gold* humano de v3.

Tabla 6.3: Tiempo de análisis de una tesis completa (164 páginas) por división y modo.

Configuración	Tiempo
Interno CBI	~42 s
Interno CBS	~74 s
Interno CSH	~324 s
Repetido (caché de reporte)	~1.3 s
Corpus externo (federado)	~84 s

6.7. Significancia estadística

El uso sistemático de intervalos de confianza al 95 % es lo que da solidez a las afirmaciones cualitativas de este capítulo: el «empate» con la línea base, la «no mejora» del dominio y la «degradación» de los sintéticos se sostienen porque los intervalos se solapan o se separan de forma consistente. La honestidad estadística es, en sí misma, un resultado del trabajo.




Figura 6.4: Similitud media intra- e inter-área (experimento E-2). La diagonal (misma área) es mayor que fuera de ella, pero el solapamiento entre áreas distintas es considerable (~ 0.62 – 0.69): confirma que la similitud es afinidad temática, y justifica que un modelo por dominio no aporte.




Figura 6.5: Tiempo de análisis por división. El costo crece con el tamaño del corpus (CSH, 10.7M de fragmentos), dominado por la capa de recuperación léxica y de carga única.

Capítulo 7

Discusión

7.1. «El dato supera a la arquitectura»

La evidencia del Capítulo 6 converge en una tesis central. Tres resultados independientes apuntan en la misma dirección: (i) los modelos contextuales *empanan* con la línea base previa, sin superarla, pese a su mayor sofisticación; (ii) los datos sintéticos —por LLM o por retro-traducción— *no* ayudan y a menudo degradan; y (iii) la especialización por dominio *no* aporta. Si la arquitectura fuera la palanca, alguna de estas variaciones habría movido la aguja; no lo hizo. Lo que sí importa es el **dato humano de calidad**: con decenas de pares bien anotados se alcanza el techo del problema a esta escala. Este es un mensaje valioso y contra-intuitivo en una época que privilegia modelos cada vez mayores.

7.2. Similitud no es plagio

El hallazgo de que el corpus es esencialmente original obliga a un diseño responsable. Un detector que reportara toda similitud alta como sospecha produciría una avalancha de falsas alarmas por afinidad temática, *boilerplate* y bibliografía compartida. Por eso el sistema cuenta en su puntaje titular *solo lo confirmado* por el clasificador y segrega lo institucional y lo citado. La similitud es un indicio para el revisor humano, no un veredicto.

7.3. Limitaciones declaradas

Con honestidad, el trabajo tiene límites que conviene explicitar:

- **Anotador único.** El conjunto de referencia (*gold*) lo anotó el propio autor; no hay un segundo anotador ni una medida de acuerdo inter-anotador. Es la limitación más importante: las métricas descansan sobre un solo criterio.
- **Test pequeño y acoplado.** Los conjuntos de prueba son de tamaño modesto —el histórico tiene solo 38 pares— lo que produce intervalos de confianza *muy anchos* (BETO v3: IC95 % [0.61, 1.00]; Tabla 6.2) y hace que ninguna comparación entre sistemas sea significativa. Además, parte de sus positivos provienen del propio recuperador (posible sesgo optimista) y, de los positivos del conjunto histórico, varios son *boilerplate* institucional o textos generados por LLM, no paráfrasis humana prototípica. El AUROC estable mitiga, pero no elimina, estas reservas.
- **OCR parcial.** La recuperación de texto de tesis escaneadas se demostró en un lote; completar el total quedó fuera de alcance por su costo frente a su bajo peso relativo.

- **Documentos en inglés.** Se procesan por traducción automática, con el ruido que ello introduce, declarado en la interfaz.
- **Demostración con CSH parcial.** El entorno gratuito sirve CSH como muestra; el sistema completo con las tres divisiones reside en el despliegue canónico.

7.4. Consideraciones éticas e integridad académica

Un detector de paráfrasis toca directamente la reputación de las personas, por lo que su uso debe ser responsable. El sistema se concibe como *apoyo* al revisor, no como juez automático: no emite acusaciones, sino evidencia acompañada de su fuente para que un humano decida. La coherencia obliga: un proyecto que exige originalidad a otros se somete a la misma vara, reportando solo cifras defendibles y sometiéndose a una auditoría independiente. El manejo del corpus respeta el carácter institucional de los documentos.

7.5. Sobre la reproducibilidad y la integridad de las cifras

Todo el trabajo es reproducible: el código y la documentación residen en un repositorio, los artefactos pesados (índices y modelos) se distribuyen por separado, y el sistema está en producción y es verificable. La distinción entre números *canónicos* y *prohibidos*, fijada por la auditoría (Anexo A), es la garantía de que ninguna cifra de este documento proviene de una fuga de datos o de un balanceo artificial.

Capítulo 8

Conclusiones

Este proyecto diseñó, implementó, evaluó y desplegó un sistema de detección de paráfrasis y copia sobre el corpus de tesis TESIAMI, basado en modelos de lenguaje contextuales y de gran escala, y bajo un protocolo de evaluación deliberadamente honesto. A continuación se retoman las hipótesis y los objetivos planteados en el Capítulo 1.

8.1. Verificación de las hipótesis

- **H1 (eficiencia de datos)** — *Confirmada con matiz*. Los modelos contextuales *igualan* a la línea base con órdenes de magnitud menos dato anotado, pero no la superan de forma significativa. El aporte es la eficiencia de datos, no un salto de exactitud.
- **H2 (los sintéticos no ayudan)** — *Confirmada*. Ninguna ampliación sintética superó al *gold* humano; varias lo degradaron.
- **H3 (similitud $\neq$ plagio)** — *Confirmada*. La búsqueda exhaustiva mostró que el corpus es original; la similitud observada es afinidad temática.

8.2. Cumplimiento de los objetivos

Se cumplieron los cinco objetivos particulares: se afinaron y compararon modelos frente a líneas base y a la tesis previa (O1); se definió y aplicó un protocolo sin fuga de datos ni balanceo, con intervalos de confianza (O2); se midió —negativamente— el efecto de los datos sintéticos (O3); se construyó el sistema de doble modo con recuperación híbrida sobre las tres divisiones (O4); y se integró el corpus externo y se desplegó el sistema de forma reproducible (O5). El objetivo general —un detector honesto y operativo— quedó satisfecho.

8.3. Aportaciones

Las aportaciones principales son: un *protocolo de evaluación honesto* replicable; la *evidencia de eficiencia de datos* frente al aumento sintético en un problema real en español; el *hallazgo de originalidad* del corpus institucional; y un *sistema desplegado y reproducible* útil para la comunidad de la unidad.

8.4. Dificultades y aprendizajes

La principal dificultad fue metodológica: reconocer y corregir las fugas de datos y los balanceos que inflaban las cifras iniciales, aun cuando ello significó reportar números más modestos pero verdaderos. El principal aprendizaje se resume en la tesis central del trabajo: **a esta escala, el dato humano de calidad supera a la arquitectura**. Un sistema cuyo valor no está en un número llamativo, sino en que cada una de sus cifras se puede defender.

Bibliografía

- [1] D. Luna Luna, “Detección de paráfrasis utilizando algoritmos de aprendizaje maquina,” Tesis de Maestría, Universidad Autónoma Metropolitana — Unidad Iztapalapa, Ciudad de México, 2022.
- [2] A. Vaswani *et al.*, “Attention is all you need,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
- [3] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, “BERT: Pre-training of deep bidirectional transformers for language understanding,” in *Proc. NAACL-HLT*, 2019.
- [4] J. Cañete *et al.*, “Spanish pre-trained BERT model and evaluation data (BETO),” in *PML4DC at ICLR*, 2020.
- [5] A. Conneau *et al.*, “Unsupervised cross-lingual representation learning at scale (XLM-R),” in *Proc. ACL*, 2020.
- [6] Y. Liu *et al.*, “RoBERTa: A robustly optimized BERT pretraining approach,” *arXiv:1907.11692*, 2019.
- [7] N. Reimers and I. Gurevych, “Sentence-BERT: Sentence embeddings using Siamese BERT-networks,” in *Proc. EMNLP-IJCNLP*, 2019.
- [8] T. Mikolov, K. Chen, G. Corrado, and J. Dean, “Efficient estimation of word representations in vector space,” *arXiv:1301.3781*, 2013.
- [9] P. Bojanowski, E. Grave, A. Joulin, and T. Mikolov, “Enriching word vectors with subword information (FastText),” *Trans. ACL*, 2017.
- [10] J. Johnson, M. Douze, and H. Jégou, “Billion-scale similarity search with GPUs (FAISS),” *IEEE Trans. Big Data*, 2019.
- [11] Yu. A. Malkov and D. A. Yashunin, “Efficient and robust approximate nearest neighbor search using hierarchical navigable small world graphs (HNSW),” *IEEE Trans. PAMI*, 2018.
- [12] S. Robertson and H. Zaragoza, “The probabilistic relevance framework: BM25 and beyond,” *Foundations and Trends in Information Retrieval*, 2009.
- [13] G. V. Cormack, C. L. A. Clarke, and S. Büttcher, “Reciprocal rank fusion outperforms Condorcet and individual rank learning methods,” in *Proc. SIGIR*, 2009.
- [14] Y. Yang *et al.*, “PAWS-X: A cross-lingual adversarial dataset for paraphrase identification,” in *Proc. EMNLP-IJCNLP*, 2019.

-
- [15] Y. Zhang, J. Baldridge, and L. He, “PAWS: Paraphrase adversaries from word scrambling,” in *Proc. NAACL-HLT*, 2019.
 - [16] W. B. Dolan and C. Brockett, “Automatically constructing a corpus of sentential paraphrases (MRPC),” in *Proc. IWP*, 2005.
 - [17] H. Touvron *et al.*, “Llama 2: Open foundation and fine-tuned chat models,” *arXiv:2307.09288*, 2023.
 - [18] J. Priem, H. Piwowar, and R. Orr, “OpenAlex: A fully-open index of scholarly works, authors, venues, institutions, and concepts,” *arXiv:2205.01833*, 2022.
 - [19] R. Kinney *et al.*, “The Semantic Scholar Open Data Platform,” *arXiv:2301.10140*, 2023.

Apéndice A

Anexos

A.1. Manual de usuario del sistema

El sistema se usa desde un navegador web y puede instalarse como aplicación (PWA).


- **Acceso.** Se ingresa a la dirección de producción y se autentica el usuario.
- **Modo 1 (comparar dos textos).** Se pegan dos textos y el sistema devuelve la etiqueta (copia, paráfrasis o revisar) con su probabilidad.
- **Modo 2 (analizar un documento).** Se pega el texto o se sube el PDF de una tesis, se elige la división (CBI, CBS o CSH) y el corpus (interno, externo o ambos); el sistema entrega el reporte de similitud con evidencia y resaltado.
- **Comparaciones adicionales.** Comparación uno contra uno de dos documentos y comparación de un fragmento contra una fuente en la web.
- **Instalación.** Desde el navegador, la opción «Instalar» agrega la aplicación al dispositivo.

Vistas del sistema

El sistema incluye módulos de información que explican su funcionamiento al usuario. La Figura A.3 reproduce el módulo «Cómo funciona», que documenta la arquitectura completa —entrada, recuperación híbrida en paralelo, modelos expertos y reglas de decisión— con los mismos números verificables del proyecto. La Figura A.4 muestra el módulo de ejemplos (casos de prueba listos para usar) y el Modo 2 en su versión móvil.

A.2. Reproducibilidad

El código, la documentación y los experimentos residen en un repositorio privado del proyecto. Los artefactos pesados (índices FAISS/BM25 y modelos) se distribuyen por separado por su tamaño. El sistema está desplegado y es verificable: un entorno canónico con las tres divisiones al 100 % y una demostración pública con CSH como muestra. Una guía de reproducibilidad documenta el entorno, los comandos y la ubicación de los artefactos.



(a) Página de inicio (escritorio).



(b) Inicio (móvil).

Figura A.1: Página de inicio del sistema: acceso, divisiones (CBI, CBS, CSH) y datos del corpus, en escritorio y en su versión móvil responsiva.

A.3. Números canónicos y números prohibidos

La Tabla A.1 resume, tal como los fijó la auditoría independiente, los valores válidos (con su conjunto de prueba) y los descartados por fuga de datos o balanceo artificial. Ninguna cifra de este documento proviene de la segunda lista.

A.4. Inventario de experimentos

El proyecto se desarrolló en ciclos semanales; cada ciclo dejó entregables trazables: conjuntos de datos y de prueba, cuadernos de afinamiento, informes de evaluación, código del sistema y bitácoras de desarrollo. El conjunto de estos entregables sustenta cada afirmación del presente reporte y está disponible en el repositorio del proyecto.

Tabla A.1: Números canónicos (válidos) y prohibidos (descartados).

Canónicos (válidos)	Prohibidos (descartados)
BETO v3 F1 = 0.842 sobre <code>test_v3_limpio</code> (38 pares).	F1 = 0.947: conjunto de 60 pares balanceado y con fuga al entrenamiento.
XLM-R v4 F1 $\approx$ 0.81 / AUROC $\approx$ 0.84 sobre <code>test_v4</code> (109).	F1 = 1.000: LLM en un test diminuto con proporción artificial.
Ensamble AUROC hasta 0.999 (robustez).	F1 $\approx$ 0.97–0.99 del « <i>pipeline tesis</i> »: pares de fragmentos consecutivos, que no son paráfrasis.
Sintéticos degradan (BETO v4–v7 < v3).	F1 internos de v4–v7 ($\approx$ 1.0): sobreajuste a la distribución sintética.




Figura A.2: Detector en su versión móvil (PWA instalable): navegación apilada, selección de clasificador y aviso de similitud. El escudo institucional conserva su proporción.






Figura A.3: Módulo «Cómo funciona»: el sistema explica su propia arquitectura al usuario, del documento al veredicto, incluyendo el papel opcional del LLM como árbitro.



(a) Módulo «Ejemplos» (escritorio).



(b) Modo 2 (móvil).

Figura A.4: Módulo de ejemplos con casos de prueba, y la búsqueda en el corpus (Modo 2) en su versión móvil responsiva.