



**Universidad Autónoma Metropolitana**

Unidad Iztapalapa

División de Ciencias Básicas e Ingeniería

Licenciatura en Computación

---

## **Proyecto Terminal de investigación 1**

### **Reporte de Actividades Semana 1 y 2**

### **Detección Inteligente de Paráfrasis mediante Modelos de Lenguaje de Gran Escala (LLM).**

*Análisis de tesis base, evaluación de repositorios TESIUAMI y BINDANI, scraping, construcción del corpus y verificación de datos*

---

**Asesor:** Dr. Benjamin Moreno Montiel

**Alumno:** Juan Antonio Guadalupe Soria Rodríguez

**Matrícula:** 2203041232

**Grupo:** CK06

**Fecha:** Mayo 2026

# Índice

---

|                                                                       |           |
|-----------------------------------------------------------------------|-----------|
| <b>1. Introducción y Descripción del Proyecto</b>                     | <b>3</b>  |
| 1.1. Contexto y Motivación . . . . .                                  | 3         |
| 1.2. Objetivos del Proyecto . . . . .                                 | 3         |
| 1.3. La “Mutación” Metodológica: de CNN+RNN a LLMs . . . . .          | 4         |
| <b>2. Análisis de la Tesis Base: David Luna Luna (2022)</b>           | <b>5</b>  |
| 2.1. Datos de la Tesis . . . . .                                      | 5         |
| 2.2. Corpus CBI-M-00-21 . . . . .                                     | 5         |
| 2.3. Generación de Paráfrasis: Traducción en Cascada . . . . .        | 6         |
| 2.4. Representación Vectorial . . . . .                               | 6         |
| 2.5. Modelos y Resultados . . . . .                                   | 7         |
| <b>3. Glosario de Términos</b>                                        | <b>8</b>  |
| <b>4. Evaluación de Repositorios: TESIUAMI vs. BINDANI</b>            | <b>13</b> |
| 4.1. Descripción de los Repositorios . . . . .                        | 13        |
| 4.1.1. TESIUAMI (Repositorio Legado) . . . . .                        | 13        |
| 4.1.2. BINDANI (Repositorio Nuevo) . . . . .                          | 13        |
| 4.2. Metodología de Comparación . . . . .                             | 14        |
| 4.2.1. Extracción de TESIUAMI . . . . .                               | 14        |
| 4.2.2. Extracción de BINDANI . . . . .                                | 14        |
| 4.2.3. Correspondencia y Verificación . . . . .                       | 14        |
| 4.3. Resultados Verificados — TESIUAMI . . . . .                      | 15        |
| 4.4. Resultados Verificados — BINDANI . . . . .                       | 16        |
| 4.5. Análisis Comparativo TESIUAMI vs. BINDANI . . . . .              | 16        |
| 4.6. Caso Crítico: Licenciatura en Computación . . . . .              | 17        |
| 4.7. Distribución Temporal del Corpus TESIUAMI Completo . . . . .     | 18        |
| 4.8. Distribución por Grado en BINDANI . . . . .                      | 19        |
| <b>5. Construcción del Corpus: Scraping de TESIUAMI</b>               | <b>20</b> |
| 5.1. Arquitectura del Sistema TESIUAMI . . . . .                      | 20        |
| 5.2. Descubrimiento del Catálogo . . . . .                            | 20        |
| 5.3. Implementación del Scraper: <code>scrape_all.py</code> . . . . . | 21        |
| 5.4. Fragmento Clave del Scraper . . . . .                            | 22        |
| 5.5. Script Complementario: <code>descargar_cbi.py</code> . . . . .   | 22        |

|                                                                             |           |
|-----------------------------------------------------------------------------|-----------|
| 5.6. Script de Verificación: <code>verificacion_numeros.py</code> . . . . . | 23        |
| 5.7. Fallos de Descarga en CBI (59 Registros) . . . . .                     | 24        |
| 5.8. Estructura del Corpus . . . . .                                        | 27        |
| <b>6. Comparativa: Corpus Luna vs. Corpus TESIUAMI Completo</b>             | <b>28</b> |
| <b>7. Hallazgos y Observaciones</b>                                         | <b>29</b> |
| 7.1. Hallazgos Técnicos de TESIUAMI . . . . .                               | 29        |
| 7.2. Hallazgos de BINDANI . . . . .                                         | 29        |
| 7.3. Verificación de Números del Documento Previo . . . . .                 | 30        |
| <b>8. Próximos Pasos</b>                                                    | <b>31</b> |

# 1 Introducción y Descripción del Proyecto

---

## 1.1 Contexto y Motivación

La integridad académica constituye un pilar fundamental en las instituciones de educación superior. El plagio, y en particular la **paráfrasis** como mecanismo de ocultación, plantea un desafío significativo para los sistemas de detección automatizada. La paráfrasis consiste en reformular un texto original conservando su significado semántico pero alterando su forma superficial, haciéndola difícil de detectar con métodos de comparación directa.

El presente proyecto tiene como objetivo construir y evaluar un sistema de detección de paráfrasis aplicado al corpus de tesis académicas de la Universidad Autónoma Metropolitana, Unidad Iztapalapa (UAM-I). Este trabajo continúa y amplía la investigación de la tesis de maestría de **David Luna Luna (2022)**, introduciendo un cambio paradigmático: la transición de modelos CNN+RNN hacia **modelos de lenguaje de gran escala (LLMs)** con aprendizaje en contexto (*in-context learning*).

## 1.2 Objetivos del Proyecto

1. Analizar exhaustivamente la tesis base de David Luna (2022) como punto de partida metodológico.
2. Construir un glosario de términos técnicos para el dominio de la detección de paráfrasis.
3. Evaluar los repositorios digitales TESIUAMI y BINDANI, verificando el estado de migración entre ambos sistemas.
4. Desarrollar e implementar un sistema de *web scraping* para extraer el catálogo completo de TESIUAMI.
5. Construir el corpus documental de tesis de la UAM-I en formato PDF con metadatos estructurados.
6. Documentar hallazgos, discrepancias y recomendaciones para las fases subsecuentes del proyecto.

### 1.3 La “Mutación” Metodológica: de CNN+RNN a LLMs

El cambio fundamental respecto al trabajo de Luna consiste en:

- **Luna (2022):** Word2Vec + CNN/LSTM entrenados desde cero sobre corpus propio.
- **Este proyecto:** LLMs pre-entrenados con *in-context learning* y *few-shot classification*.

Las ventajas de esta mutación son:

1. Elimina la necesidad de entrenar embeddings específicos del dominio.
2. Aprovecha el conocimiento lingüístico general acumulado en los LLMs.
3. Permite prototipado rápido con mínimos datos etiquetados.
4. Escala naturalmente a corpus más grandes (factor 26x respecto al corpus de Luna).

## 2 Análisis de la Tesis Base: David Luna Luna (2022)

### 2.1 Datos de la Tesis

| Campo       | Valor                                                                 |
|-------------|-----------------------------------------------------------------------|
| Título      | Detección de Paráfrasis Utilizando Algoritmos de Aprendizaje Maquinal |
| Autor       | David Luna Luna                                                       |
| Grado       | Maestría en Ciencias (Ciencias y Tecnologías de la Información)       |
| Institución | UAM Iztapalapa                                                        |
| Año         | 2022                                                                  |
| División    | CBI                                                                   |

**Tabla 1:** Datos bibliográficos de la tesis base.

### 2.2 Corpus CBI-M-00-21

El aporte principal de Luna fue la creación del corpus **CBI-M-00-21**, una colección de 817 tesis de maestría de CBI-UAM-I, periodo 2000–2021.

| Disciplina   | Documentos | Páginas       | Segmentos      |
|--------------|------------|---------------|----------------|
| Matemáticas  | 184        | 15,193        | —              |
| Química      | 262        | 21,386        | —              |
| Computación  | 72         | 5,438         | —              |
| Biomédica    | 150        | 10,606        | —              |
| Física       | 102        | 6,911         | —              |
| Energía      | 47         | 5,122         | —              |
| <b>Total</b> | <b>817</b> | <b>64,656</b> | <b>601,982</b> |

**Tabla 2:** Distribución del corpus CBI-M-00-21 por disciplina.

A partir de los 601,982 segmentos se generaron **1,203,964 pares candidatos** a paráfrasis.

## 2.3 Generación de Paráfrasis: Traducción en Cascada

Luna implementó generación automática de paráfrasis mediante el motor de traducción **MariaMT**:

1. **Traducción directa:** español  $\rightarrow$  inglés (MariaMT).
2. **Retro-traducción:** inglés  $\rightarrow$  español (MariaMT).
3. **Filtrado:** verificación de similitud semántica con el original.

Límites aplicados: máximo 5,000 segmentos por corrida; filtros de longitud (variación  $\leq 50\%$ ) y umbral de similitud del coseno.

## 2.4 Representación Vectorial

Cada par de oraciones se codificó como una **matriz**  $8 \times 300$ :

$$M = \begin{bmatrix} v_1 \\ v_2 \\ v_1 \ominus v_2 \\ v_1 \odot v_2 \\ v_2 \\ v_1 \\ v_2 \ominus v_1 \\ v_2 \odot v_1 \end{bmatrix}$$

donde  $v_i$  son vectores Word2Vec (CBOW, ventana=5, dim=300),  $\ominus$  diferencia elemento a elemento y  $\odot$  producto elemento a elemento.

## 2.5 Modelos y Resultados

| Modelo              | Sushi        | MRPC         | Quora        | CBI-M-00-21  |
|---------------------|--------------|--------------|--------------|--------------|
| Naive Bayes         | 0.710        | —            | —            | —            |
| SVM                 | <b>0.917</b> | —            | —            | —            |
| Regresión Log.      | 0.850        | —            | —            | —            |
| CNN                 | 0.880        | 0.820        | 0.910        | 0.950        |
| LSTM                | 0.900        | 0.840        | 0.930        | <b>0.970</b> |
| Ensemble (Stacking) | —            | <b>0.852</b> | <b>0.946</b> | <b>0.970</b> |

**Tabla 3:** Resultados (F1-Score) por modelo y corpus.

**Conclusiones clave:** LSTM y Ensemble alcanzan  $F1=0.970$  en CBI-M-00-21 (mejor rendimiento); LSTM supera a CNN en todas las configuraciones; el ensemble mejora la robustez mediante stacking de 5 LSTMs con meta-clasificador MLP.



## 3 Glosario de Términos

---

### Paráfrasis

Dos textos se consideran paráfrasis cuando poseen formas lingüísticas distintas pero transmiten aproximadamente el mismo significado semántico. Este fenómeno constituye el mecanismo más común para ocultar el plagio académico, ya que permite reformular el contenido de una fuente original sin alterar su sentido fundamental. En el contexto de esta tesis, la detección de paráfrasis se aborda como un problema de clasificación binaria, donde cada par de segmentos textuales se etiqueta como paráfrasis o no paráfrasis. La identificación automática de paráfrasis resulta crucial para preservar la integridad académica en instituciones educativas.

### Aprendizaje Automático

El aprendizaje automático (también conocido como *aprendizaje maquinal* o *machine learning*) es una rama de la inteligencia artificial que permite a los sistemas informáticos aprender patrones y tomar decisiones a partir de datos, sin ser explícitamente programados para cada tarea específica. Los algoritmos de aprendizaje automático construyen modelos matemáticos basados en datos de entrenamiento, los cuales generalizan para realizar predicciones o tomar decisiones sobre datos nuevos no vistos durante el entrenamiento. En este proyecto se emplean tanto modelos clásicos (Naive Bayes, SVM, regresión logística) como modelos basados en redes neuronales para la clasificación de pares de segmentos textuales.

### Aprendizaje Profundo

El aprendizaje profundo (*deep learning*) es una subdisciplina del aprendizaje automático que utiliza redes neuronales artificiales con múltiples capas ocultas para aprender representaciones jerárquicas de los datos. Estas arquitecturas profundas permiten capturar patrones complejos y abstracciones de alto nivel sin necesidad de ingeniería de características manual. En el ámbito de la detección de paráfrasis, el aprendizaje profundo ha demostrado un rendimiento superior al de los métodos tradicionales, particularmente mediante el uso de redes convolucionales y recurrentes que procesan directamente las representaciones vectoriales de los textos.

## Red Neuronal Convolutiva (CNN)

Una red neuronal convolutiva es un tipo de arquitectura de aprendizaje profundo que aplica filtros deslizantes (*kernels*) sobre los datos de entrada para extraer patrones locales de forma jerárquica. Originalmente diseñadas para el procesamiento de imágenes, las CNN se adaptan al problema de detección de paráfrasis tratando las matrices de similitud entre oraciones como si fueran “imágenes” bidimensionales. La arquitectura empleada en esta tesis consta de dos capas convolutivas con 32 y 64 filtros respectivamente, seguidas de capas de agrupación (*pooling*) y una capa fully-connected para la clasificación final.

## Red Neuronal Recurrente (RNN/LSTM)

Las redes neuronales recurrentes están diseñadas para procesar datos secuenciales, como texto o series temporales, manteniendo un estado interno que captura información de los elementos anteriores de la secuencia. La variante LSTM (*Long Short-Term Memory*) introduce compuertas (*gates*) que controlan el flujo de información dentro de la celda de memoria, resolviendo el problema del desvanecimiento del gradiente que afecta a las RNN tradicionales. En este trabajo se implementan LSTMs con 4 pasos de tiempo y entre 32 y 512 neuronas por capa, logrando un rendimiento superior al de las CNN en la tarea de clasificación.

## Embedding

Un *embedding* es una representación vectorial densa de una palabra (o frase) en un espacio continuo de baja dimensionalidad, donde las palabras semánticamente similares se ubican próximas entre sí. A diferencia de las representaciones dispersas como *one-hot encoding*, los embeddings capturan relaciones semánticas y sintácticas entre términos. En esta tesis se utilizan modelos Word2Vec con arquitectura CBOW, ventana de contexto de 5 palabras y vectores de 300 dimensiones, además de FastText para manejar palabras fuera del vocabulario mediante subunidades de caracteres.

## Corpus

Un corpus es una colección estructurada y generalmente etiquetada de textos utilizada como fundamento para la investigación lingüística o el entrenamiento de modelos de aprendizaje automático. El corpus CBI-M-00-21, desarrollado específicamente para esta tesis, contiene 817 tesis de maestría del área de Ciencias Básicas e Ingeniería de la UAM Iztapalapa, abarcando el periodo 2000–2021. Otros corpus empleados incluyen Sushi (pa-

res de paráfrasis en español), MRPC (*Microsoft Research Paraphrase Corpus*) y Quora (*Quora Question Pairs*), los cuales permiten evaluar la generalización de los modelos en diferentes dominios.

### Aprendizaje en Contexto (*In-Context Learning*)

El aprendizaje en contexto es una técnica que permite a los modelos de lenguaje de gran escala (*LLMs*) realizar tareas específicas sin necesidad de ajuste fino (*fine-tuning*), proporcionando únicamente ejemplos ilustrativos dentro del *prompt* de entrada. El modelo infiere la tarea a partir de los ejemplos presentados y genera la respuesta esperada para una nueva consulta. Esta aproximación resulta particularmente útil cuando se dispone de pocos datos etiquetados o cuando se requiere prototipado rápido de soluciones de clasificación textual.

### Aprendizaje con Pocos Ejemplos (*Few-Shot Learning*)

El aprendizaje con pocos ejemplos es un paradigma del aprendizaje automático donde el modelo debe aprender a realizar una tarea a partir de únicamente unos cuantos ejemplos etiquetados. Este enfoque contrasta con los métodos tradicionales supervisados que requieren grandes volúmenes de datos anotados. *Few-shot learning* resulta especialmente relevante en escenarios donde la anotación manual de datos es costosa o el fenómeno de interés es poco frecuente, como ocurre con ciertos tipos de paráfrasis en corpus académicos especializados.

### Similitud del Coseno

La similitud del coseno es una medida de semejanza entre dos vectores en un espacio multidimensional, calculada como el coseno del ángulo formado entre ellos. Su valor oscila entre  $-1$  y  $1$ , donde  $1$  indica vectores idénticos en dirección,  $0$  indica ortogonalidad y  $-1$  indica direcciones opuestas. En el contexto de esta tesis, la similitud del coseno se emplea para comparar los vectores de embeddings generados por FastText, estableciendo un umbral de  $0,9$  para considerar dos segmentos textuales como candidatos a paráfrasis.

## Precisión, Recall y F1-Score

La precisión (*precision*) mide la proporción de predicciones positivas correctas sobre el total de predicciones positivas realizadas por el modelo. El *recall* (también llamado exhaustividad o sensibilidad) mide la proporción de casos positivos reales que fueron correctamente identificados. El F1-Score es la media armónica de ambas métricas, proporcionando una medida balanceada del rendimiento del clasificador. Estas tres métricas constituyen el estándar para evaluar sistemas de clasificación binaria como el detector de paráfrasis desarrollado en esta tesis.

## Tokenización

La tokenización es el proceso de dividir un texto en unidades más pequeñas denominadas *tokens*, que pueden ser palabras completas, subpalabras o caracteres individuales, dependiendo del nivel de granularidad requerido. Este paso constituye una etapa fundamental del preprocesamiento en cualquier sistema de procesamiento de lenguaje natural. En el proyecto se implementó una tokenización a nivel de palabras considerando los signos de puntuación como tokens independientes, seguida de la eliminación de palabras vacías (*stopwords*) y caracteres no alfabéticos.

## Traducción Automática (MariaMT)

La traducción automática consiste en el uso de sistemas computacionales para traducir texto de un idioma a otro sin intervención humana. MariaMT es un motor de traducción automática basado en redes neuronales que se emplea en esta tesis para generar paráfrasis mediante el método de *traducción en cascada*: el texto original en español se traduce al inglés y posteriormente se retro-traduce al español, produciendo reformulaciones semánticamente equivalentes pero con diferente estructura superficial. Se utilizó un límite de 5,000 segmentos por corrida para mantener la calidad de las traducciones generadas.

## API REST

Una API REST (*Representational State Transfer*) es un estilo de arquitectura de software para sistemas distribuidos que utiliza el protocolo HTTP para realizar operaciones de acceso y manipulación de recursos. Las operaciones fundamentales (GET, POST, PUT, DELETE) se corresponden con las operaciones CRUD (*Create, Read, Update, Delete*). En el contexto de este proyecto, se empleó una API REST para interactuar con el servicio de traducción MariaMT, enviando solicitudes HTTP con los segmentos textuales a traducir y recibiendo las respuestas correspondientes.

## Web Scraping

El *web scraping* es una técnica computacional que permite la extracción automatizada de datos desde sitios web mediante programas que simulan la navegación humana. Esta técnica se utilizó en la fase de construcción del corpus CBI-M-00-21 para descargar de manera sistemática las tesis de maestría disponibles en los repositorios digitales de la UAM Iztapalapa, automatizando el proceso de recolección de los documentos PDF que posteriormente serían convertidos a texto plano para su análisis.

## 4 Evaluación de Repositorios: TESIUAMI vs. BINDANI

---

### 4.1 Descripción de los Repositorios

#### 4.1.1 TESIUAMI (Repositorio Legado)

**URL:** <http://tesiuami.izt.uam.mx/uam/default.php>

TESIUAMI es el repositorio heredado de tesis electrónicas de la UAM Iztapalapa. Opera sobre una arquitectura PHP legada con las siguientes características:

- Sistema de búsqueda basado en formularios POST a `test.php`.
- Resultados paginados a 40 registros por página.
- PDFs accesibles directamente sin autenticación vía `tesis.php`.
- Interfaz gráfica de la época 2000–2010 (framesets HTML).
- **Limitación crítica:** certificado SSL expirado (solo accesible por HTTP).
- **Paginación engañosa:** TESIUAMI devuelve los mismos registros de forma cíclica en múltiples páginas (aproximadamente 2x duplicados), requiriendo deduplicación por `recno`.

#### 4.1.2 BINDANI (Repositorio Nuevo)

**URL:** <https://bindani.izt.uam.mx/>

BINDANI (Biblioteca Digital de la UAM Iztapalapa) es el sistema moderno que reemplaza a TESIUAMI. Características:

- Plataforma moderna Ruby on Rails con interfaz responsiva.
- Soporta múltiples idiomas (ES, EN, DE, FR, IT, PT, ZH).
- Licencia Creative Commons BY-NC 4.0.
- Indexado por motores de búsqueda (Google Scholar, etc.).
- Facetas de búsqueda por tipo, división, grado, año, autor, asesor.

- No expone un endpoint OAI-PMH público accesible.
- El catálogo interno (`/catalog`) requiere referer o sesión para acceso.

## 4.2 Metodología de Comparación

### 4.2.1 Extracción de TESIUAMI

1. Se maparon **94 titulaciones** en las tres divisiones académicas (CBI, CBS, CSH).
2. Se iteró sobre todas las páginas de cada titulación vía POST a `test.php`.
3. Se extrajeron `recno`, `doc`, título, año, autores y asesores.
4. **Deduplicación:** se identificaron registros únicos por `recno`.
5. Se guardaron índices JSON por división y un índice global.

### 4.2.2 Extracción de BINDANI

1. Se accedió al catálogo público con cabeceras de navegador estándar.
2. Se extrajeron facetas de búsqueda: tipo, división, grado, titulación.
3. Se verificó la presencia/ausencia de la Licenciatura en Computación.

### 4.2.3 Correspondencia y Verificación

La correspondencia se realizó comparando título, autores y año. Adicionalmente, se verificó:

- El conteo de duplicados en TESIUAMI (factor  $\approx 2x$  por paginación cíclica).
- La validez del recuento mediante verificación cruzada de dos titulaciones representativas.

### 4.3 Resultados Verificados — TESIUAMI

| División                                                 | Registros Únicos | PDFs Descargados |
|----------------------------------------------------------|------------------|------------------|
| CBI (Ciencias Básicas e Ingeniería)                      | 5,120            | 5,062            |
| CBS (Ciencias Biológicas y de la Salud)                  | 5,417            | 0                |
| CSH (Ciencias Sociales y Humanidades)                    | 10,749           | 0                |
| <b>Total UAM-I</b>                                       | <b>21,286</b>    | <b>5,062</b>     |
| Catálogo completo TESIUAMI (incluye otras instituciones) | 22,821           | —                |

**Tabla 4:** Registros en TESIUAMI verificados con el índice local (`indice_global.json`).

| Titulación CBI (top)          | Únicos (scraper) | Raw TESIUAMI |
|-------------------------------|------------------|--------------|
| Lic. en Computación           | 784              | 1,572        |
| Lic. en Ingeniería Biomédica  | 714              | ≈1,428       |
| Lic. en Ingeniería en Energía | 406              | ≈812         |
| Lic. en Ingeniería Química    | 306              | ≈612         |
| Dr. en Ciencias (Química)     | 278              | ≈556         |
| M. en Ciencias (Ing. Química) | 273              | ≈546         |

**Tabla 5:** Comparación de conteos brutos vs. deduplicados para titulaciones CBI seleccionadas. El factor de duplicación en TESIUAMI es  $\approx 2x$  debido a la paginación cíclica.



## 4.4 Resultados Verificados — BINDANI

Los siguientes datos se obtuvieron directamente del catálogo público de BINDANI en mayo 2026:

| Métrica                                 | Cantidad      | Fuente                              |
|-----------------------------------------|---------------|-------------------------------------|
| Total items BINDANI                     | <b>13,411</b> | Catálogo público (“1–10 de 13,411”) |
| Trabajo Recepcional de Licenciatura     | 6,896         | Faceta “Type”                       |
| Tesiuam (posgrado)                      | 6,316         | Faceta “Type”                       |
| Libros                                  | 110           | Faceta “Type”                       |
| Artículos                               | 89            | Faceta “Type”                       |
| CSH (Ciencias Sociales y Humanidades)   | 9,051         | Faceta División                     |
| CBI (Ciencias Básicas e Ingeniería)     | 2,282         | Faceta División                     |
| CBS (Ciencias Biológicas y de la Salud) | 2,099         | Faceta División                     |
| Other                                   | 2             | Faceta División                     |
| Idioma español                          | 13,381        | Faceta Idioma                       |
| Idioma inglés                           | 16            | Faceta Idioma                       |

**Tabla 6:** Datos reales de BINDANI obtenidos del catálogo público (mayo 2026).

## 4.5 Análisis Comparativo TESIUAMI vs. BINDANI

| División           | TESIUAMI      | BINDANI        | Migración     |
|--------------------|---------------|----------------|---------------|
| CSH                | 10,749        | 9,051          | <b>84.2 %</b> |
| CBI                | 5,120         | 2,282          | <b>44.6 %</b> |
| CBS                | 5,417         | 2,099          | <b>38.7 %</b> |
| <b>Total UAM-I</b> | <b>21,286</b> | <b>13,411*</b> | <b>63.0 %</b> |

**Tabla 7:** Comparativa de migración TESIUAMI→BINDANI con datos verificados en mayo 2026.  
(\*) Total BINDANI incluye libros y artículos.

**Nota** el análisis comparativo generado previamente (9 de mayo 2026) utilizaba el total TESIUAMI de 22,821 (catálogo completo incluyendo otras instituciones) y datos de BINDANI. Los datos actuales (17 de mayo 2026) muestran que BINDANI ha crecido: CSH pasó de 8,929 a 9,051 (+122), CBI de 2,128 a 2,282 (+154), CBS de 1,812 a 2,099 (+287).

## 4.6 Caso Crítico: Licenciatura en Computación

| Métrica                                      | Valor          | Observación                        |
|----------------------------------------------|----------------|------------------------------------|
| Registros en TESIUAMI (únicos, deduplicados) | 784            | Verificado con scraper             |
| Entradas brutas TESIUAMI (con duplicados)    | 1,572          | Verificado en vivo                 |
| Factor de duplicación TESIUAMI               | $\approx 2.0x$ | Consistente con otras titulaciones |
| Registros en BINDANI                         | 0              | No aparece en catálogo             |
| Porcentaje migrado                           | 0 %            | CRÍTICO                            |


**Tabla 8:** Estado de la Licenciatura en Computación: caso crítico verificado.

### Implicaciones críticas:


- **784 tesis** de Lic. en Computación son accesibles *únicamente* en TESIUAMI.
- Si TESIUAMI es discontinuado sin respaldo, se pierden definitivamente.
- El **corpus de referencia para este proyecto** (fuente de tesis de Computación) está en TESIUAMI, *no* en BINDANI.
- TESIUAMI permanece como la única fuente viable para la Licenciatura en Computación.

## 4.7 Distribución Temporal del Corpus TESIUAMI Completo

El índice global de TESIUAMI contiene **21,286 registros** de las tres divisiones (CBI, CBS, CSH), de los cuales **21,163 (99.4 %)** tienen año de publicación asignado, abarcando el periodo 1978–2026. La década de mayor producción es 2000–2009 con 6,098 tesis (28.8 % del total con año).



**Figura 1:** Distribucion del corpus TESIUAMI por periodo y division (21,163 registros con ano). La decada 2000-2009 concentra la mayor produccion con 6,098 tesis.



**Figura 2:** Comparativa TESIUAMI vs BINDANI por division. BINDANI tiene 13,411 ítems totales; la migración global es del 63.0 %, con CSH mejor representada (84.2 %) y CBS rezagada (38.7 %).

#### 4.8 Distribución por Grado en BINDANI


| Tipo de recurso                          | BINDANI      |
|------------------------------------------|--------------|
| Tesina (licenciatura)                    | 4,072        |
| Maestría (masterThesis)                  | 3,829        |
| Doctorado (doctoralThesis)               | 2,195        |
| Proyecto Terminal (licenciatura)         | 1,477        |
| Trabajo Terminal (licenciatura)          | 1,246        |
| <b>Total posgrado (M+D)</b>              | <b>6,024</b> |
| <b>Total licenciatura (Tesina+PT+TT)</b> | <b>6,795</b> |

**Tabla 9:** Distribución por tipo de recurso en BINDANI (mayo 2026).

## 5 Construcción del Corpus: Scraping de TESIAMI

### 5.1 Arquitectura del Sistema TESIAMI

El repositorio TESIAMI expone los documentos a través del siguiente flujo:



La URL de descarga directa de PDFs es:

`tesis.php?ip=&documento={doc}&recno={recno}`

### 5.2 Descubrimiento del Catálogo

Mediante el análisis del formulario `search_form.php` se identificaron **94 titulaciones** distribuidas en tres divisiones:

| División     | Titulaciones | Tipos           |
|--------------|--------------|-----------------|
| CBI          | 28           | Lic, M, Dr, Esp |
| CBS          | 21           | Lic, M, Dr, Esp |
| CSH          | 45           | Lic, M, Dr, Esp |
| <b>Total</b> | <b>94</b>    | —               |

**Tabla 10:** Titulaciones mapeadas en el scraper.

### 5.3 Implementación del Scraper: `scrape_all.py`

El scraper implementa las siguientes estrategias:

**Paginación exhaustiva:**

Itera sobre páginas sucesivas hasta obtener una página vacía. Esto es crítico porque la interfaz visual de TESIUAMI muestra solo 11 páginas, pero el servidor devuelve registros hasta que la página queda vacía (40+ páginas para titulaciones grandes).

**Deduplicación por `recno`:**

Los registros se identifican unívocamente por su número de récord (**`recno`**). La deduplicación es necesaria porque TESIUAMI devuelve los mismos registros cíclicamente en páginas sucesivas (factor  $\approx 2x$ ).

**Enriquecimiento de metadatos:**

Para cada registro se extraen del contexto HTML: año de publicación, lista de autores y lista de asesores, además del título y la URL del PDF.

**Rate limiting:**

0.35 segundos entre peticiones para respetar la capacidad del servidor y evitar bloqueos.

**Verificación de PDFs:**

Cada descarga verifica: (1) código HTTP 200; (2) cabecera `%PDF`; (3) tamaño  $>10$  KB.

## 5.4 Fragmento Clave del Scraper

```

1 def scrape_titulacion(titulacion_sql):
2     """Escrapea todas las páginas de una titulación hasta página vacía."""
3     all_entries = []
4     pag = 1
5     while True:
6         html = fetch_page(pag, titulacion_sql)
7         entries = parse_entries(html) # deduplicación interna por recno
8         if not entries:
9             break # página vacía = fin del catálogo
10        for e in entries:
11            enrich_entry(e, html) # extrae año, autores, asesores
12            all_entries.extend(entries)
13            pag += 1
14            time.sleep(0.35) # rate limiting
15        return all_entries
16
17 def scrape_division(division):
18     """Deduplicación global por recno entre todas las titulaciones."""
19     todos = {}
20     for tit_sql in TITULACIONES[division]:
21         entries = scrape_titulacion(tit_sql)
22         for e in entries:
23             r = e["recno"]
24             if r not in todos: # deduplicación global
25                 todos[r] = e
26     return todos

```

**Listing 1:** Función de paginación exhaustiva en `scrape_all.py`

## 5.5 Script Complementario: `descargar_cbi.py`

Mientras que `scrape_all.py` orquesta la extracción completa, `descargar_cbi.py` es un script especializado que descarga únicamente los PDFs de CBI faltantes, saltando los que ya existen:

### Detección de existentes:

Verifica si el PDF ya fue descargado (tamaño >10 KB) y lo salta automáticamente.

### Validación de integridad:

Cada descarga verifica: código HTTP 200, cabecera %PDF y tamaño mínimo.

**Reanudable:**

Al estar diseñado para ejecuciones múltiples, solo descarga los PDFs que faltan, ideal para completar el corpus después de interrupciones.

**5.6 Script de Verificación: `verificacion_numeros.py`**

Este script verifica las estadísticas del corpus TESIAMI contra los datos publicados y BINDANI. Se ejecuta de forma independiente y produce:

- **Conteo de registros únicos** en el índice global, desglosado por división (CBI, CBS, CSH).
- **Conteo de PDFs descargados** por división, contrastando con los registros del índice.
- **Verificación en vivo** del número de tesis de Lic. en Computación en TESIAMI mediante peticiones directas al servidor, útil para validar que el scraper no omitió registros.
- **Datos de BINDANI** obtenidos del catálogo público, incluyendo total de items, distribución por tipo y por división académica.

**Importancia:** La verificación en vivo detectó que TESIAMI reporta 784 registros de Lic. en Computación en su interfaz visual ( $\times 10$  páginas), pero el scraper con deduplicación encontró solo  $\approx 400$  únicos, confirmando el factor de duplicación  $\approx 2x$ . También confirmó que BINDANI tiene 0 registros de Lic. en Computación, validando la necesidad de usar TESIAMI como fuente principal.

| División     | Registros     | PDFs OK       | Fallidos   | Tamaño       |
|--------------|---------------|---------------|------------|--------------|
| CBI          | 5,120         | 5,062         | 60 (1.1 %) | 30 GB        |
| CBS          | 5,417         | 0 (pendiente) | —          | —            |
| CSH          | 10,749        | 0 (pendiente) | —          | —            |
| <b>Total</b> | <b>21,286</b> | <b>5,062</b>  | <b>60</b>  | <b>30 GB</b> |

**Tabla 11:** Estado de la construcción del corpus TESIAMI (mayo 2026).



## 5.7 Fallos de Descarga en CBI (59 Registros)

De los 5,120 registros CBI, 59 PDFs (1.15 %) no pudieron descargarse: 52 con error HTTP 404 (archivo inexistente en el servidor), 3 con código 200 (respuesta sin contenido útil), 1 con código 300 (redirección incompleta) y 3 por timeout de conexión. Lista completa:

| Archivo       | Título                                                  | Autor                             | Error |
|---------------|---------------------------------------------------------|-----------------------------------|-------|
| UAM583.pdf    | SISTEMA DE IDENTIFICACION DE MADERAS                    | OCTAVIO ENRIQUE SANCHEZ GONZALEZ  | 404   |
| UAM7860.pdf   | ESPECTROSCOPIA DE CORRELACION DE FOTONES PARA SISTEM... | ROGELIO RODRIGUEZ TALAVERA        | 404   |
| UAMI10755.pdf | SOFTWARE PARA LA ENSEÑANZA DE LOS ALGORITMOS            | ROCIO RESENDIZ MUÑOZ              | 200   |
| UAMI10824.pdf | TRANSMISION DE UNA SEÑAL BIOMEDICA POR RADIOFRECUENCIA  | MARTIN MONTALVO PONCE             | 200   |
| UAMI13022.pdf | APLICACION DE MICROCONTROLADORES                        | ARLES MONICA MENDEZ DELGADILLO    | 200   |
| UAMI15887.pdf | LIMPIEZA DEL GAS DE SINTESIS PRODUCIDO EN LA GASIFIC... | HECTOR ISAI FRANCISCO RODRIGUEZ   | 404   |
| UAMI17022.pdf | IMPORTANCIA DE LA CONSERVACION DE LA MASA EN MODELOS... | ROCIO MENDOZA FLORES              | 404   |
| UAMI17032.pdf | NADADORES BROWNIANOS EN UN POTENCIAL ARMÓNICO EN PR...  | JULIO CESAR HIDALGO GONZALEZ      | 404   |
| UAMI17033.pdf | PROPAGADORES EN MECANICA CUANTICA POLIMERICA: PARTIC... | ERNESTO FLORES GONZÁLEZ           | 404   |
| UAMI17039.pdf | DINAMICA MOLECULAR SOBRE LA SOLUBILIDAD Y PRECIPITAC... | ROBERTO CRUZ VELAZQUEZ            | 404   |
| UAMI17043.pdf | DISTRIBUCION DE TEMPERATURAS EN POZOS GEOTERMICOS       | MARCO ALONSO TOLEDO DORANTES      | 404   |
| UAMI17492.pdf | DISEÑO DE UNA PLANTA PARA PRODUCIR COBRE UTILIZANDO...  | BRENDA ANAHI SEGURA BAILON        | 404   |
| UAMI17494.pdf | REVISTA ELECTRONICA                                     | DARELY ALARCON PANTOJA            | 404   |
| UAMI17495.pdf | MEMBRANAS DE PVC-OXIDO DE GRAFENO Y SU USO POTENCIAL... | DEUSDEDIT DEMETRIO VALLEJO ARENAS | 404   |
| UAM12504.pdf  | SISTEMATIZACION Y AUTOMATIZACION DE UNA AGENCIA DE U... | ROSALINDA VILLARRUEL JIMENEZ      | 404   |
| UAM21784.pdf  | ARTE Y CIENCIA (MANEJO DE IMAGENES FRACTALES)           | MAURICIO ARTURO RAMOS ELTON       | 404   |

| Archivo       | Título                                                       | Autor                         | Error |
|---------------|--------------------------------------------------------------|-------------------------------|-------|
| UAMI22557.pdf | NANO-ACARREADORES PARA LA PROTECCION Y LIBERACION CO...      | ANA YESENIA HERNANDEZ VITE    | 404   |
| UAMI22558.pdf | REPORTE DE PROYECTO TERMINAL                                 | BLANCA PATRICIA LARA SANCHEZ  | 404   |
| UAMI22559.pdf | DESARROLLO DE BATERIAS DE ION-LITIO PARA SU ACOPLAMIENTO...  | MARICRUZ BAUTISTA RAMIREZ     | 404   |
| UAMI22561.pdf | ANALISIS E IMPLEMENTACION PRACTICA DE ALGORITMOS PAR...      | RODRIGO WONG HERNANDEZ        | 404   |
| UAMI22585.pdf | DETERMINACION DE LAS CONDICIONES ENERGETICAS PARA LA...      | CARLOS GERONIMO LOPEZ         | 404   |
| UAMI22596.pdf | SIMULACION PARALELA DE REDES POROSAS                         | JORGE MATADAMAS HERNANDEZ     | 404   |
| UAMI22608.pdf | SINTESIS Y CARACTERIZACION DE POLIMEROS Y COPOLIMERO...      | JUANA CUETO MARTINEZ          | 404   |
| UAMI22609.pdf | USO DE POLIMEROS HIDROFOBOS POR PLASMA PARA EL TRATA...      | MARCO ANTONIO FARIAS SALDIVAR | 404   |
| UAMI22610.pdf | FLUJO SANGUINEO CEREBRAL. DIFERENCIA DE GENERO EN SU...      | KARLA PAULINA ZEA ESPINOSA    | 404   |
| UAMI22611.pdf | EXTRACCION DE ADN DE CEPAS DE ESCHERICHIA COLI EN EN...      | LORENA LOPEZ SOSA             | 404   |
| UAMI22612.pdf | ESTUDIO TEORICO DEL MNO                                      | MARCOS RIVERA ALMAZO          | 404   |
| UAMI22613.pdf | PORTAL WEB DE RYT (EXTENSIONES AL SISTEMA MEMORYT)           | MARISOL VAZQUEZ ESPINOSA      | 404   |
| UAMI22614.pdf | EVIDENCIA DE LA FORMACION DEL COMPLEJO COBRE (II)-B...       | MARTHA RUBI TRUJILLO VAZQUEZ  | 404   |
| UAMI22615.pdf | DESARROLLO DE SISTEMAS DE SOFTWARE CON PSP Y TSP             | MAURICIO FENTON GARCIA        | 404   |
| UAMI22616.pdf | CAVITACION HIDRODINAMICA PARA EL TRATAMIENTO DE AGUA...      | RAUL EDUARDO LUNA JACINTO     | 404   |
| UAMI22694.pdf | DISEÑO E IMPLEMENTACION DE UN DISPOSITIVO PARA MONI...       | GERARDO ZUBIRAN MARTINEZ      | 404   |
| UAMI22695.pdf | ANALISIS Y EVALUACION DE LOS CICLOS DE $CEO_2/CE_2O_3$ Y ... | KATIA ALEJANDRA AGUILAR MEJIA | 404   |
| UAMI22696.pdf | ESTUDIO Y DISEÑO DE UN PROCESO DE ADSORCION DE COLO...       | LESLIE FIGUEROA RODRIGUEZ     | 404   |
| UAMI22697.pdf | MODELADO, SIMULACION DINAMICA Y CONTROL DE LA TRANSF...      | LIZBETH N. SAAVEDRA FERNANDEZ | 404   |

| Archivo            | Título                                                     | Autor                            | Error |
|--------------------|------------------------------------------------------------|----------------------------------|-------|
| UAMII22698.pdf     | PROCESAMIENTO DE SEÑALES SEMG DE REGISTROS MULTICAN...     | ELOISA FLORES CRUZ               | 404   |
| UAMII23479.pdf     | MATERIA PROGRAMABLE                                        | YONATAN ALDANA SALDAÑAS          | 404   |
| UAMII23482.pdf     | ANALISIS DE BIOMARCADORES EN LA ALMEJA POLYMESODACA...     | JOSE ROBERTO JERONIMO JUAREZ     | 404   |
| UAMII23483.pdf     | SISTEMAS CUANTICOS EN MODELOS COSMOLOGICOS ISOTROPOS...    | FLAVIO JOAO PINEDA ARVIZU        | 404   |
| UAMII23488.pdf     | APLICACION DE UN ALGORITMO GENETICO MULTIOBJETIVO PA...    | VICTOR HUGO ESCANDON BAILON      | 404   |
| UAMII23494.pdf     | ANALISIS DE LA DINAMICA DEL MODELO DE MAASCHSALTZMA...     | MARCO POLO GARCIA RIVERA         | 404   |
| UAMII23498.pdf     | DESCOMPOSICION EMPIRICA EN MODOS Y ANALISIS POR COMP...    | MAURICIO ARTURO MARTINEZ CAMACHO | 404   |
| UAMII24939.pdf     | TRANSICIONES ESTRUCTURALES EN SISTEMAS AUTOENSAMBLAD...    | NOE DE JESUS ATZIN CAÑAS         | 404   |
| UAMII25141.pdf     | INVESTIGACION TEORICA DINAMICA EFECTIVA POLIMERICA D...    | ANGEL JOEL SANJUAN GARCIA        | 404   |
| UAMII25142.pdf     | TRANSMISION MEJORADA DE LUZ EN PELICULAS METALICAS. ...    | ESTEFANIA CASTAÑEDA DE LA VEGA   | 404   |
| UAMII25143.pdf     | CRECIMIENTO DE PELICULAS METALICAS EN EL LIMITE DE P...    | ESTEFANIA CASTAÑEDA DE LA VEGA   | 404   |
| UAMII25144.pdf     | INVESTIGACION TEORICA DINAMICA EFECTIVA POLIMERICA D...    | ANGEL JOEL SANJUAN GARCIA        | 404   |
| UAMII30006.pdf     | ESTUDIO DE LOS CAMBIOS METABOLICOS EN EL ENVEJECIMIENTO... | IXCHEL DAFNE AVENDAÑO PACHECO    | 404   |
| UAMII30069.PDF.PDF | ARMAMENTO Y BALISTICA                                      | BRISA ANAYATZIN URIBE GUZMAN     | 404   |
| UAMII30075.PDF.PDF | CALCULO DE LA FUNCION DE BOYS UTILIZANDO INTEGRACION...    | ADAN BARBOSA JIMENEZ             | 404   |
| UAMII30091:PDF.PDF | USO DE LA RESONANCIA MAGNETICA NUCLEAR PARA REALIZAR...    | ELIZABEL GARCIA CEDAZO           | 404   |
| UAMII30332.pdf     | OBTENCION DE FIBRAS NANOMETRICAS POROSAS PARA LA RET...    | LUIS ALBERTO SILVA VALDEZ        | 404   |
| UAMII30334         | IMPLEMENTACION DE ALEXA EN DOFBOT-PI5 (VOXDOP)             | JUAN MANUEL TORRES NEQUIZ        | 300   |

| Archivo        | Título                                                   | Autor                      | Error |
|----------------|----------------------------------------------------------|----------------------------|-------|
| UAMII30342.pdf | CARACTERIZACION TERMOLU-MINISCENTE DEL BEO PARA APLIC... | DIEGO EDUARDO CALVO MEDINA | 404   |
| UAMII30343.pdf | CARACTERIZACION TERMOLU-MINISCENTE DEL BEO PARA APLIC... | DIEGO EDUARDO CALVO MEDINA | 404   |
| 210383151.pdf  | SINTESIS DE TIO2-ZNO DISPER-SOS EN SILICE: CARACTERIZ... | ALBERTO ESTRE-LLA GONZALEZ | 404   |

## 5.8 Estructura del Corpus

```

1 corpus_tesiuami/
2 +-- CBI/
3 |   +-- pdfs/           # 5,062 archivos PDF (30 GB)
4 |   +-- indice.json      # 5,120 registros con metadatos
5 +-- CBS/
6 |   +-- pdfs/           # (pendiente)
7 |   +-- indice.json      # 5,417 registros con metadatos
8 +-- CSH/
9 |   +-- pdfs/           # (pendiente)
10 |  +-- indice.json      # 10,749 registros con metadatos
11 +-- indice_global.json  # 21,286 registros consolidados
12 +-- scrape_all.py       # Script principal de extraccion
13 +-- descargar_cbi.py    # Script auxiliar para CBI
14 +-- verificacion_numeros.py # Script de verificacion de estadisticas

```

**Listing 2:** Estructura de directorios del corpus TESIAMI

## 6 Comparativa: Corpus Luna vs. Corpus TESIUAMI Completo

| Característica      | Luna (2022)         | Este Proyecto                  |
|---------------------|---------------------|--------------------------------|
| Alcance             | CBI – solo maestría | CBI + CBS + CSH                |
| Grados              | Maestría            | Todos (Lic, M, Dr, Esp)        |
| Documentos          | 817                 | 21,286                         |
| Factor de amplitud  | 1x                  | <b>26x</b>                     |
| Páginas             | 64,656              | ≈1.6M estimado                 |
| Segmentos           | 601,982             | ≈15.6M estimado                |
| PDFs disponibles    | 817                 | 5,062 (CBI)                    |
| Tamaño en disco     | N/A                 | 30 GB (CBI)                    |
| Modelo de detección | CNN / LSTM          | LLMs + ICL                     |
| Corpus destino      | CBI-M-00-21         | Lic. Computación + CBI-CBS-CSH |

**Tabla 13:** Comparativa entre el corpus de Luna y el corpus TESIUAMI completo de este proyecto.

## 7 Hallazgos y Observaciones

---

### 7.1 Hallazgos Técnicos de TESIUAMI

1. **Certificado SSL expirado:** El sitio solo es accesible vía HTTP, no HTTPS. Representa un riesgo de seguridad para los usuarios.
2. **Paginación cíclica (duplicados  $\approx 2x$ ):** TESIUAMI devuelve los mismos registros repetidos en páginas sucesivas. Verificado experimentalmente: Lic. Computación 784 únicos / 1,572 raw; Lic. Física 207 únicos / 418 raw. El factor de duplicación es consistente ( $\approx 2.0x$ ) entre titulaciones.
3. **PDFs públicos sin autenticación:** Los documentos son descargables directamente, lo que facilita la construcción del corpus pero plantea interrogantes sobre derechos de autor.
4. **Inconsistencia de nombres de archivo:** Los PDFs usan diferentes esquemas de nomenclatura: UAMxxx, UAMIxxx, UAMIIxxx, NNNNNNxxx.PDF, etc.
5. **60 PDFs con error 404:** El 1.1 % de los registros CBI referencian archivos que ya no existen en el servidor.

### 7.2 Hallazgos de BINDANI

1. **Migración incompleta:** Con datos de mayo 2026, BINDANI tiene 13,411 ítems vs. 21,286 registros UAM-I en TESIUAMI (63.0 % de migración considerando solo tesis).
2. **Brecha por división:** CSH 84.2 %  $\gg$  CBI 44.6 % > CBS 38.7 %. Las ciencias duras y biológicas están significativamente subrepresentadas.
3. **Ausencia total de Lic. Computación:** La titulación más relevante para este proyecto tiene 0 registros en BINDANI. Confirmado por ausencia en el catálogo de facetas.
4. **Posgrado bien cubierto:** Maestría (3,829) y Doctorado (2,195) están razonablemente representados; la licenciatura (Tesina 4,072 + PT 1,477 + TT 1,246 = 6,795) muestra brechas significativas.

5. **Catálogo protegido:** El endpoint `/catalog` de BINDANI devuelve 403 Forbidden sin sesión activa o referer apropiado.

### 7.3 Verificación de Números del Documento Previo

| Métrica                            | Doc. Previo | Verificado | Estado      |
|------------------------------------|-------------|------------|-------------|
| TESIUAMI total (catálogo completo) | 22,821      | 22,821     | Correcto    |
| TESIUAMI UAM-I únicos              | 21,286      | 21,286     | Correcto    |
| BINDANI total items (al momento)   | 13,411      | 13,411     | Correcto    |
| BINDANI CSH (mayo 2026)            | 8,929       | 9,051      | Actualizado |
| BINDANI CBI (mayo 2026)            | 2,128       | 2,282      | Actualizado |
| BINDANI CBS (mayo 2026)            | 1,812       | 2,099      | Actualizado |
| Lic. Computación TESIUAMI          | 786         | 784        | $\Delta=2$  |
| Lic. Computación BINDANI           | 0           | 0          | Confirmado  |
| PDFs CBI descargados               | 5,062       | 5,062      | Correcto    |
| Tamaño CBI                         | 28 GB       | 30 GB      | Actualizado |

**Tabla 14:** Verificación de números del documento comparativo previo con datos actuales (mayo 2026).

**Nota:** Las discrepancias en BINDANI (CSH, CBI, CBS) se deben a que el documento previo fue generado en una fecha anterior (9 de mayo 2026) y BINDANI ha continuado incorporando nuevos registros. Los números actualizados muestran una tendencia positiva de migración.

## 8 Próximos Pasos

---

1. **Organización de avances:** Crear una carpeta o repositorio en Drive con subcarpetas por semana (Semana 1&2, Semana 3, Semana 4, ...) para subir los avances del proyecto de forma estructurada.
2. **Base de datos y extracción de texto:** Mostrar la base de datos con los PDFs y aplicar la transformación a texto plano, generando archivos PDF junto con su correspondiente texto plano en formato JSON.
3. **Búsqueda de modelos LLM:** Investigar modelos de lenguaje de gran escala con contexto o enfoque en paráfrasis, preferentemente con orientación científica, que puedan adaptarse al dominio del proyecto.
4. **Aprendizaje en contexto (*In-Context Learning*):** Investigar a fondo esta técnica para comenzar a implementarla y evaluar la capacidad y los alcances del proyecto con este paradigma.
5. **Exploración con LLMs:** Comenzar a experimentar con LLMs para la generación de paráfrasis dado un texto de entrada; investigar las herramientas disponibles y empezar a realizar implementaciones prácticas.



## Referencias

---

## Referencias

---

- [1] Luna Luna, D. (2022). *Detección de Paráfrasis Utilizando Algoritmos de Aprendizaje Maquinal*. Tesis de Maestría. Universidad Autónoma Metropolitana, Unidad Iztapalapa.
- [2] TESIUAMI — Repositorio de Tesis Electrónicas de la UAM Iztapalapa. <http://tesiuami.izt.uam.mx/uam/default.php> [Consultado mayo 2026]
- [3] BINDANI — Biblioteca Digital de la UAM Iztapalapa. <https://bindani.izt.uam.mx/> [Consultado mayo 2026; total verificado: 13,411 ítems]
- [4] Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). Efficient estimation of word representations in vector space. *arXiv:1301.3781*.
- [5] Bojanowski, P., Grave, E., Joulin, A., & Mikolov, T. (2017). Enriching word vectors with subword information. *TACL*, 5, 135–146.
- [6] Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780.
- [7] Kim, Y. (2014). Convolutional neural networks for sentence classification. *Proceedings of EMNLP*, 1746–1751.
- [8] Brown, T.B., et al. (2020). Language models are few-shot learners. *NeurIPS*, 33, 1877–1901.
- [9] Devlin, J., Chang, M.W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers. *NAACL-HLT*, 4171–4186.